ИНЖЕНЕРНО-
МАТЕМАТИЧЕСКАЯ
ШКОЛА
НИУ ВШЭ И VK

Введение в машинное обучение на аудиоданных

Цифровая обработка сигналов

education

ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ

О курсе

- Курс познакомит вас с основными понятиями машинного обучения для обработки звука
- Сочетает базовую теорию с практикой
- Вы научитесь проектировать архитектуры нейронных сетей и обучать модели для решения прикладных задач

О курсе

6

занятий

5

домашних задания

1

экзамен

100

баллов максимум:

- по 15 за ДЗ, всего 75
- 25 за экзамен

Карта курса

1. Основы цифровой обработки сигнала
2. Основы нейронных сетей
3. Основные задачи и метрики аудио ML
4. Основы speech enhancement
5. Введение в синтез речи
6. Введение в синтез речи. Продвинутые методы

Команда курса

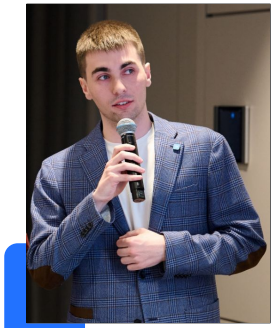

Максим Грошев

ВК Видео

Дмитрий Яковлев

T2 (TELE2)

Никита Климин

НИУ ВШЭ

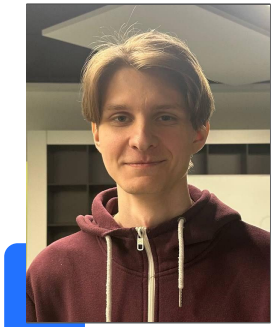

Никита Сиротинский

Аспирант МИЭМ

О лекторе

Яковлев Дмитрий

T2 (TELE2)
MLE (разработка и поддержка сервисов для DS-команд)

Опыт работы: суммарно везде 4 года

Содержание лекции

- Аудиоданные
- Частотный домен сигнала
- Звуковые эффекты - SFX

Аудиоданные.
Audio codec:
Coder АЦП & Decoder ЦАП.

раздел 1

Как хранится аудио

Аналоговый сигнал
↓
[Дискретизация] → семплы с частотой sr
↓
[Квантизация] → 16/24/32 бит
↓
Цифровой сигнал (PCM)

Импульсно-кодовая модуляция
Pulse code modulation - PCM

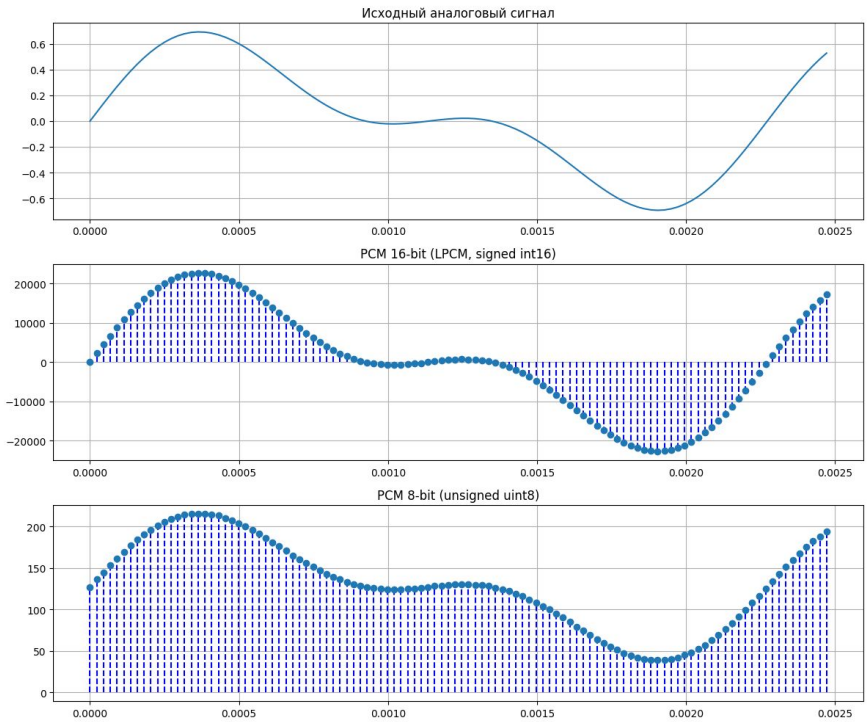

Как хранится аудио

Ключевые параметры:

- Sample Rate (sr): Количество семплов в секунду (Hz)
  - CD качество: 44,100 Hz
  - Studio: 48,000-96,000 Hz
  - Телефон: 8,000-16,000 Hz
- Bit Depth: Глубина квантизации
  - 16 бит = 65,536 уровней (CD качество)
  - 24 бит = 16,777,216 уровней (профессиональное)
  - 32 бит float = максимум точности

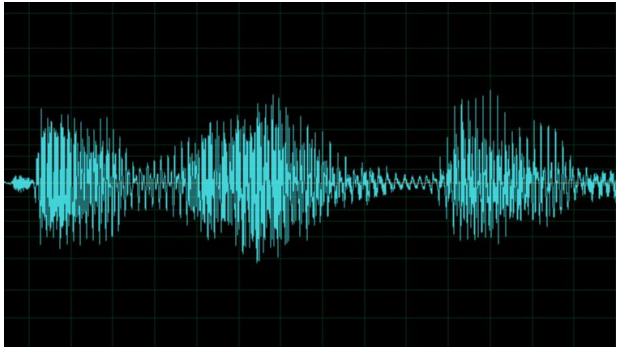

Теорема Найквиста: sr ≥ 2 × max_frequency

Как храниться аудио

Форматы без сжатия:
WAV/WAVE и AIFF

Форматы со сжатием без потерь:
FLAC, ALAC и APE

Форматы со сжатием с потерями:
MP3, AAC, WMA и OGG VORBIS

Honarable mention:
MP3 - MPEG-1 layer 3. Moving Picture Experts Group - ISO. MPEG-1 стандарты для видеокодека и аудиокодека. Layer 3 стандарт с сжатием 10:1 в отличии от Layer 1, Layer 2 вносит существенные изменения в частотном представлении.

Материалы
[MP3, AAC, WAV, FLAC: рассказываем обо всех форматах аудиофайлов]

WAV формат

Address	0	1	2	3	4	5	6	7	8	9	a	b	c	d	e	f	Dump
00000000	52	49	46	46	80	66	01	00	57	41	56	45	66	6d	74	20	RIFFЂf..WAVEfmt
00000010	10	00	00	00	01	00	01	00	44	ac	00	00	88	58	01	00	.....D¬..€X..
00000020	02	00	1														....data\f..вхЇу
00000030	35	f6	3														5ц:эряґы.щць(.В.
00000040	eb	08	3														л.5.[.l.q...).К.
00000050	01	04	5														..Q...ћ.R.П.‹...
00000060	42	0d	8														В.….г.`.b...}.g.
00000070	57	04	1														W...г.Н.ъ.Ы.Ъ.¬.
00000080	e3	07	d														г.С.В...ў.ё.Р...
00000090	00	0e	e														..й.V.a.'.".^.`.
000000a0	f3	0c	1														у...м.э.ж.ц.*.n.
000000b0	1e	11	f														..р.Я.г.1.±.м.5.
000000c0	7e	05	de	06	78	07	e4	07	47	09	70	0a	27	0a	f8	09	~.Ю.х.д.G.р.'.ш.
000000d0	6e	09	d5	08	4c	0a	b1	0b	70	0c	98	0e	de	0e	3c	0c	n.Х.L.±.р...Ю.<.

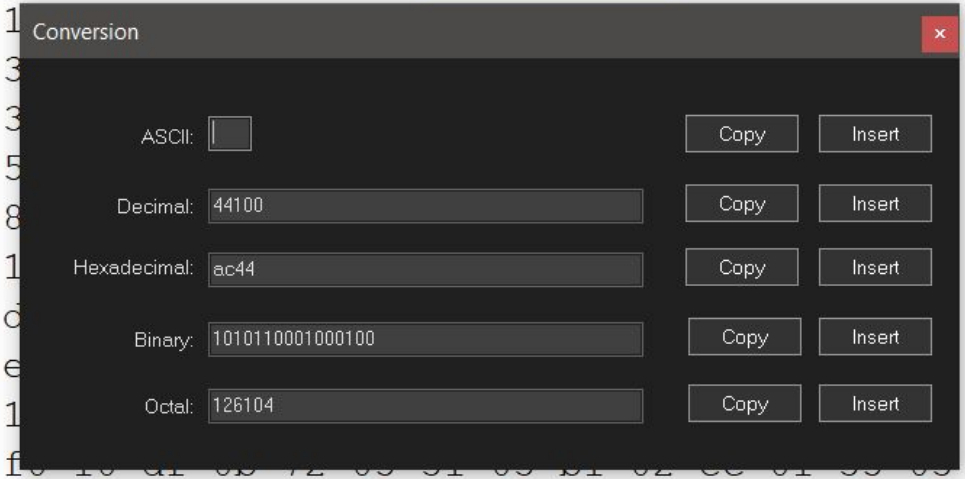

WAV формат

- Little endian - байтовые данные интерпретируются справа-налево
- на 12 смещении секции fmt определён sample rate - частота дискретизации - 44100 Гц на Audio CD
- на 10 смещении количество каналов
- в секции data кванты сигнала сгруппированы как: временной отсчёт -> канал -> значение кванта PCM

Материалы
Формат звуковых файлов WAV

Темпоральное и частотное представление

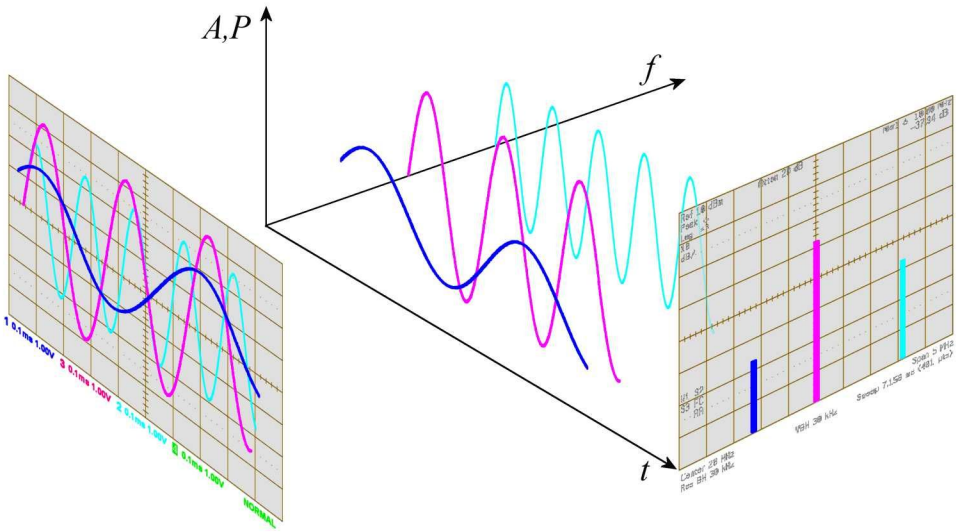

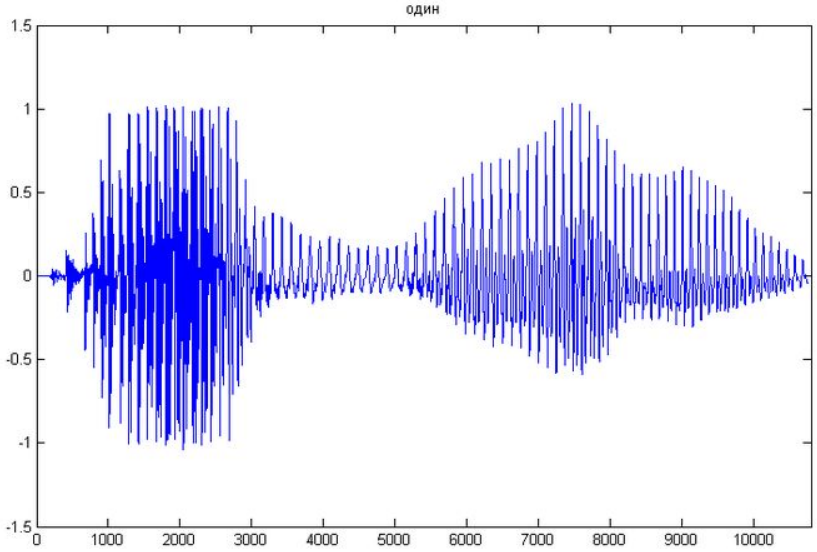

Источники иллюстраций
Основы радиолокации – Представление сигналов во временной и в частотной области

Частотный домен сигнала. Преобразование Фурье.

раздел 2

Преобразование Фурье

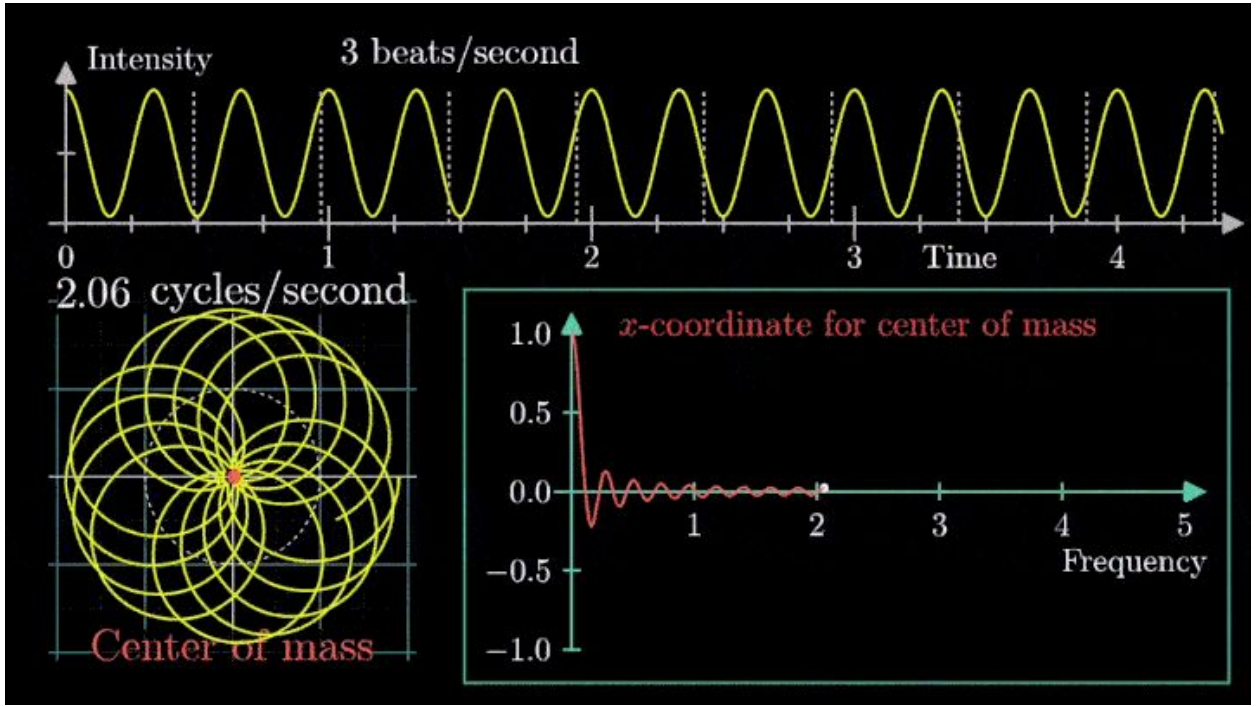

Материалы

Грант Сандерсон:

But what is a Fourier series? From heat flow to drawing with circles. [VK, YT]

But what is the Fourier Transform? A visual introduction. [VK, YT, site]

FT

$$X_k = \frac{1}{N}\sum_{n=0}^{N-1} x_n e^{-\frac{2\pi i}{N}kn} \qquad x(t) = \sum_{k=-\infty}^{+\infty} c_k e^{i\omega_k t}, \qquad \omega_k = \frac{2\pi k}{T}.$$

DFT - Дискретное преобразование фурье
x(t) - Оригинал X(w) - Изображение

Переход из непрерывного в дискретный:

- w_k -> 2pi*k/N
- t -> n
- f = k/T -> k/N

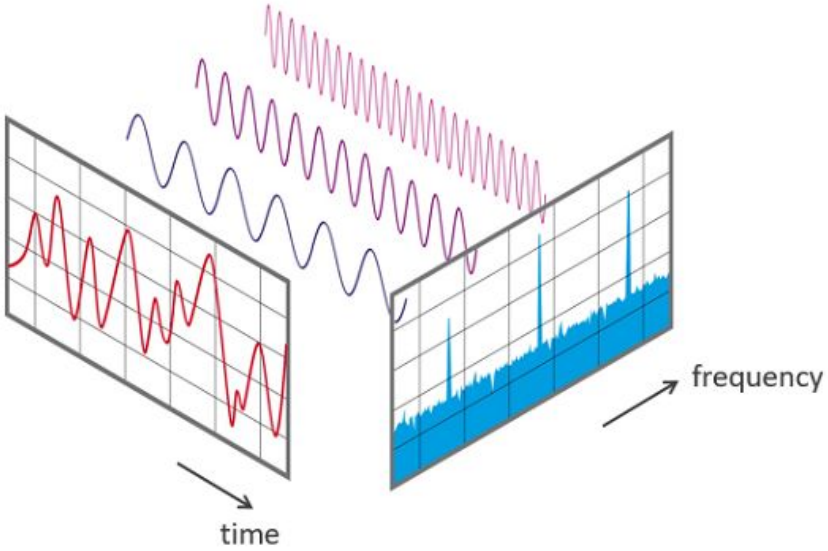

FFT

Численное преобразование Фурье:

- Основан на алгоритме Кули-Тьюки
- Имеет выигрыш при большом количестве временных отсчетов ~ O(n*logn)

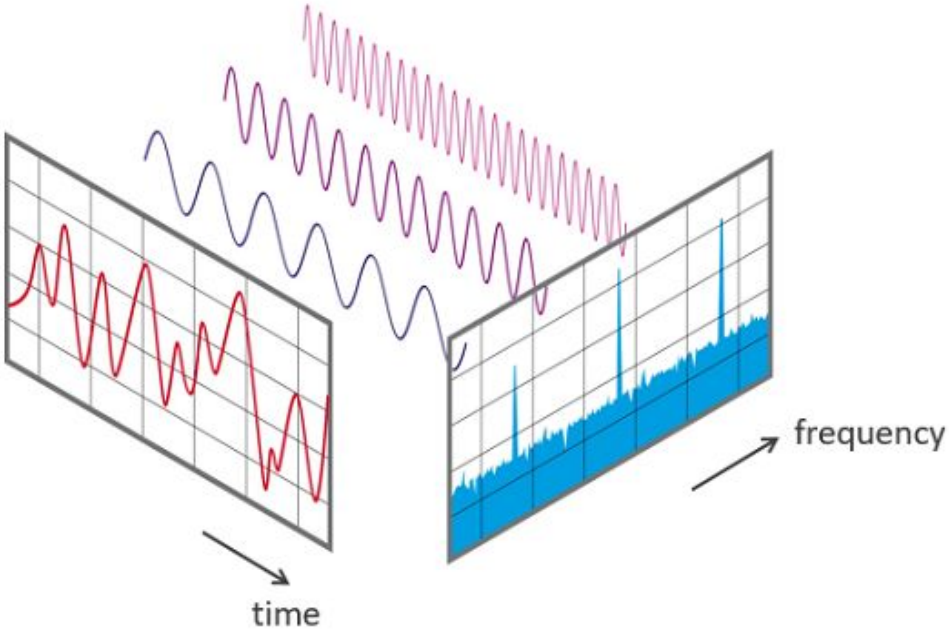

STFT

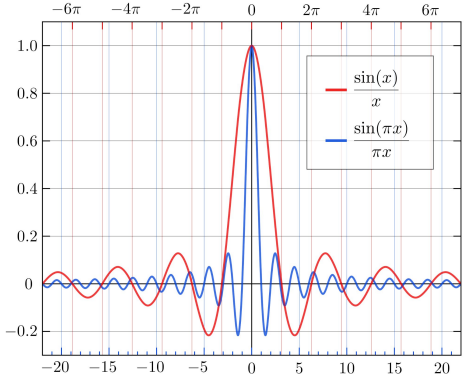

Спектрограмма
Параметры:

- n_fft - размер окна (обычно 512-4096)
- hop_length - смещение между окнами (n_fft // 4)
- window - функция окна (Hann, Hamming, Blackman)

Принцип неопределённости Гейзенберга:

- чем меньше n_fft тем лучше детализация по частоте
- НО хуже во времени и наоборот

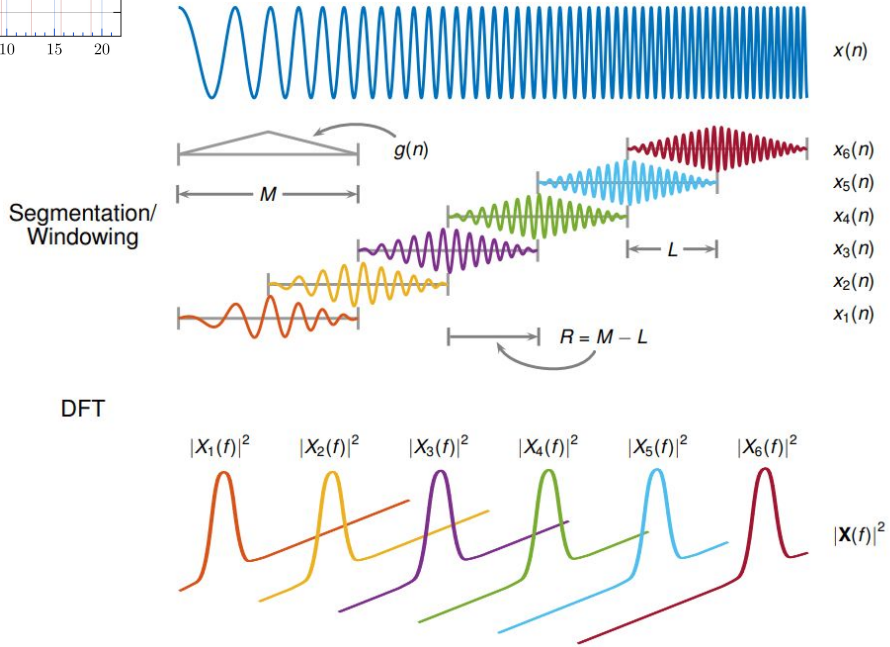

Амплитуда/Магнитуда и Фаза/Угол

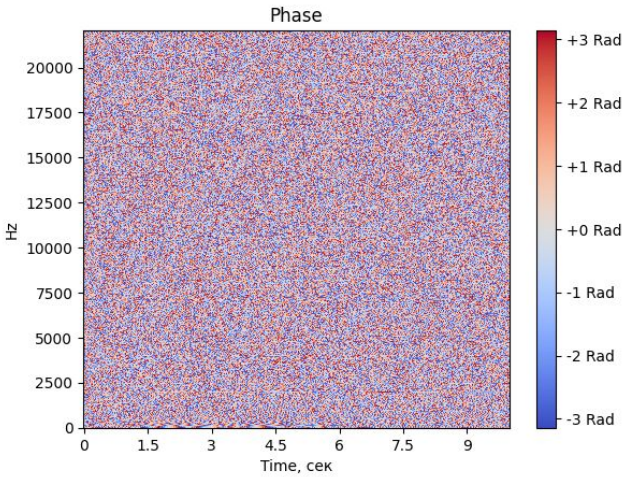

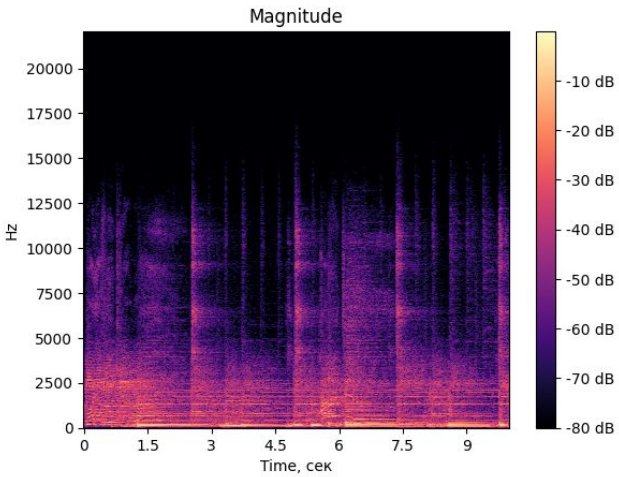

a+bi=r(cos φ + i sin φ) =re^(iφ)

Тригонометрическая форма

z = r (cos φ + i sin φ)

где r = |z| = √(a^2 + b^2) - модуль

φ = arg(z) = arctg(b/a) - аргумент

Амплитуда/Магнитуда и Фаза/Угол

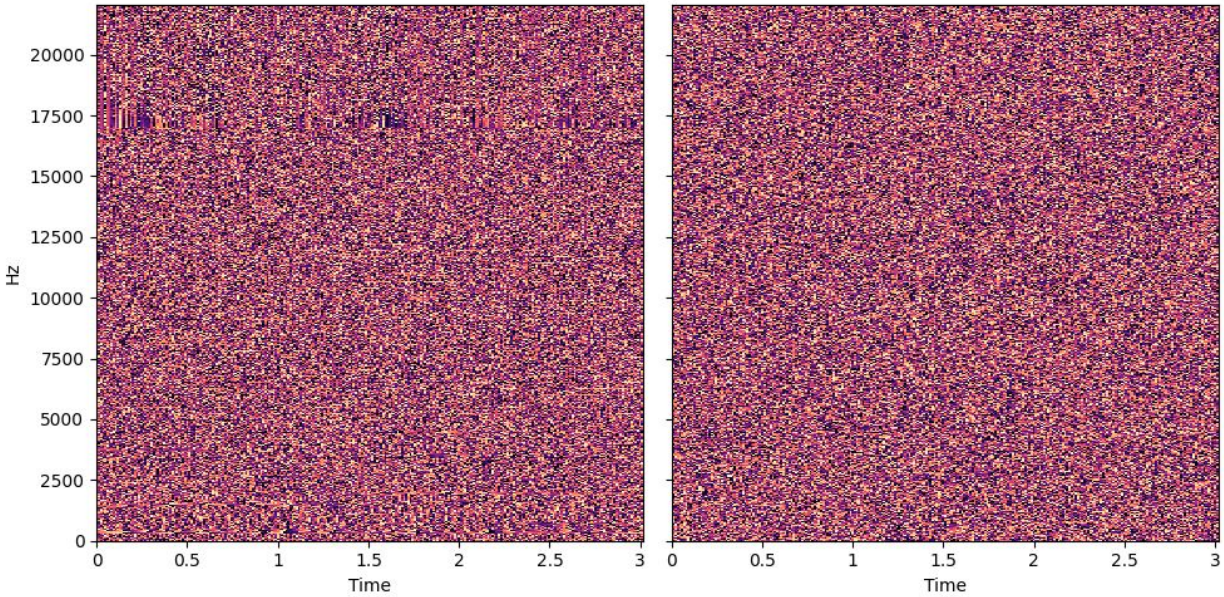

пример нормальной фазы (звук) пример рандомной фазы (звук)

Как работает Shazam

Поисковой словарь строиться:

h(f_n_1, … f_n_N) → (n, Название трека), где:

- n - временной интервал трека
- f_n_i - частота с существенным вкладом, магнитуда > пороговое значение
- h - хэш функция над частотами в n отрезке трека

Уникальных ключей в таком словаре >> значений
Стратегия поиска через нахождение НАИБОЛЬШЕЙ хронологично релевантной цепочки хэшей:
✅h0 → (n, Искомый трек), h1 → (n+1, Искомый трек), h2 → (n+2, Искомый трек)
❌h0 → (n+shift, Похожий трек), h1 → (n+shift+1, Похожий трек)

Звуковые эффекты - SFX. Обработка сигналов.

раздел 3

SFX

- Echo: Копия сигнала с задержкой
- Reverb: Множественные отражения
- Vibrato: Модуляция тональности
- Tremolo: Модуляция амплитуды
- Chorus: Echo + LFO
- Flanger: Переменная задержка
- Phaser: Смещение фазы
- Distortion: Нелинейные преобразования

Все эффекты = манипуляция амплитудой, частотой или фазой

Echo & Reverb

Одиночное отражение или множественные отражения звука

LTI (Linear Time-Invariant) эффекты
Могут быть представимы в виде свертки - ✱
$y(t) = x(t) ✱ h(t)$,
$h(t)$ - импульсный отклик
$\mathcal{L}\{h(t)\} = W(p)$ - передаточная функция $= Y(p)/X(p)$

h[n] представимо как массив размера sr*delay(s)+1 вида:
[1, 0, … 0, α], где:

- α громкость эха от 0 до 1
- 1 в начале сохраняет изначальный сигнал

Материалы
Wiki:
Импульсный отклик
Передаточная функция
musicradar:
Реверберация

Tremolo & Vibrato

"Плавающий"/"пульсирующий" эффект

LTV (Linear Time-Varying) эффекты

С помощью LFO на относительно небольшой частоте ~1-10 Гц можно изменять:

- громкость - Tremolo
- тональность(ускоряя и замедляя воспроизведение) - Vibrato

*LFO (Low Frequency Oscillator)

Distortion

"Перегруз"

LTV (Linear Time-Varying) эффект

Искажение достигается за счет:

- усиления сигнала - gain
- и применения нелинейности:
  - клиппинг - обрезка
  - гиперболический тангенс
  - арктангенс

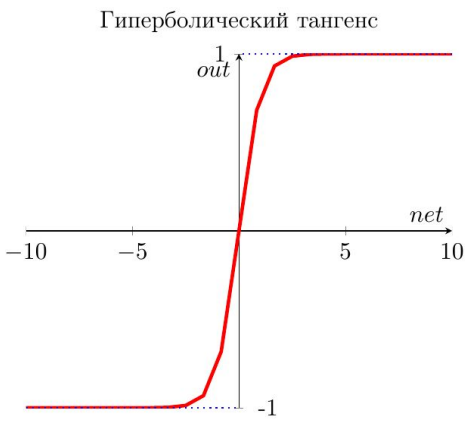

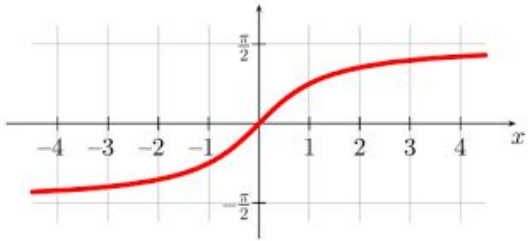

Phaser

LTV (Linear Time-Varying) эффект

Достигается за счет:

- противофаз оригинального сигнала и проведённого через каскад фильтров смещающих частоту, которые зависят от:
  - LFO
  - Обратной связи

Итоги

- Рассмотрели как хранится аудио
- Темпоральный и частотный домены сигнала
- Преобразование Фурье
- Амплитуда и фаза сигнала
- Звуковые эффекты и свертки

ДЗ

- Применить звуковые эффекты с занятия на ваш трек по выбору или из предложенных.

Спасибо за внимание!