ИНЖЕНЕРНО-
МАТЕМАТИЧЕСКАЯ
ШКОЛА
НИУ ВШЭ И VK

Задачи и метрики Audio ML

education

ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ

Проверка связи

Поставьте в чат:

+ если меня видно и слышно
– если нет

Если нет звука:

- убедитесь, что на вашем устройстве и на колонках включён звук
- обновите страницу или закройте страницу и заново присоединитесь к звонку
- перезагрузите компьютер (ноутбук) и заново попытайтесь зайти

Грошев Максим

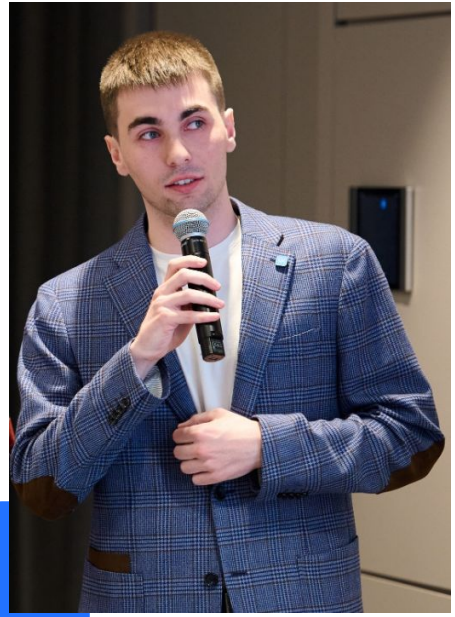

- Разработчик в команде звуковых технологий “ВК Видео”
- Выпускник Инженерно-математической школы VK и НИУ ВШЭ
- Опыт работы: 2 года

Вспоминаем прошлое занятие

Вопрос: Для чего нужна функция активации?

Вспоминаем прошлое занятие

Вопрос: Для чего нужна функция активации?

Ответ: Для добавления нелинейности к выходу предыдущего слоя. Это позволяет нейронной сети лучше моделировать сложные функции

Сегодня на занятии

1. Представление аудио
2. Audio tagging
3. Speech enchancement
4. Automatic Speech Recognition (ASR)
5. Text to speech/Speech synthesis (TTS)

Представление аудио

раздел 1

Представление аудио: Wave

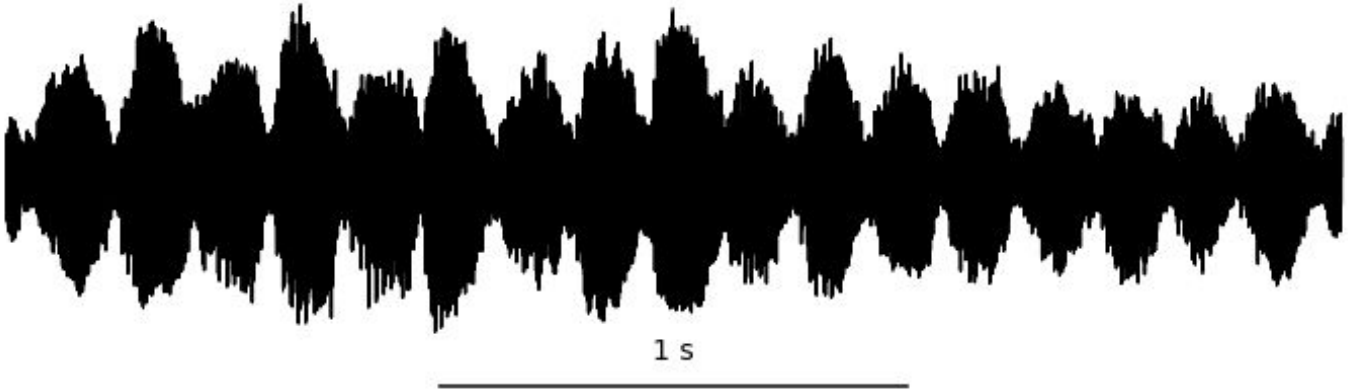

Представление аудио: STFT

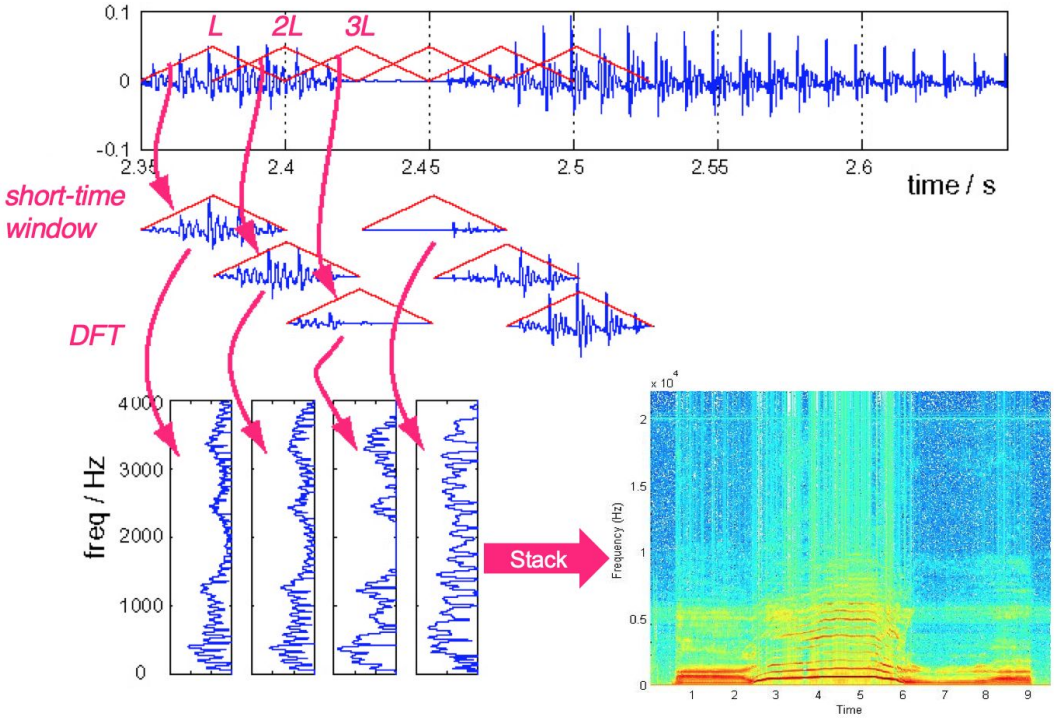

Представление аудио: log spec

$$M(f) = 1127,01048 \ln(1 + f/700).$$

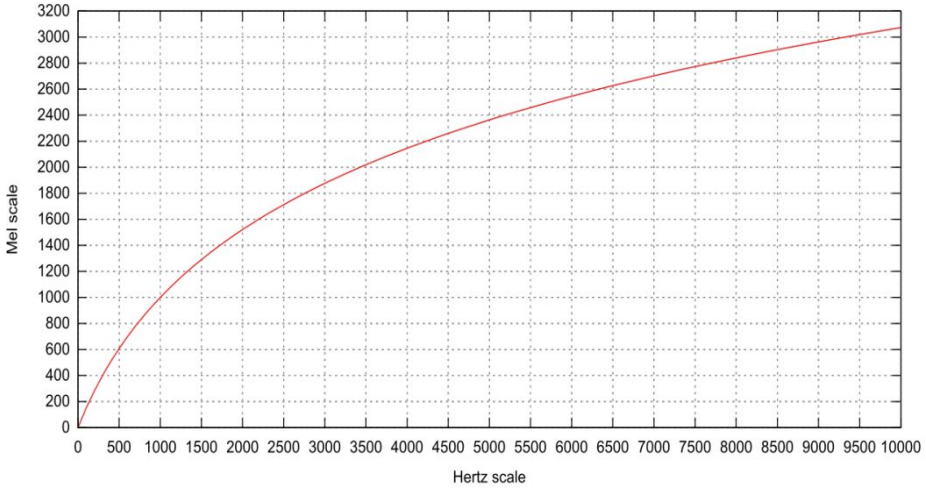

Рис. 1: График зависимости частоты от мел.

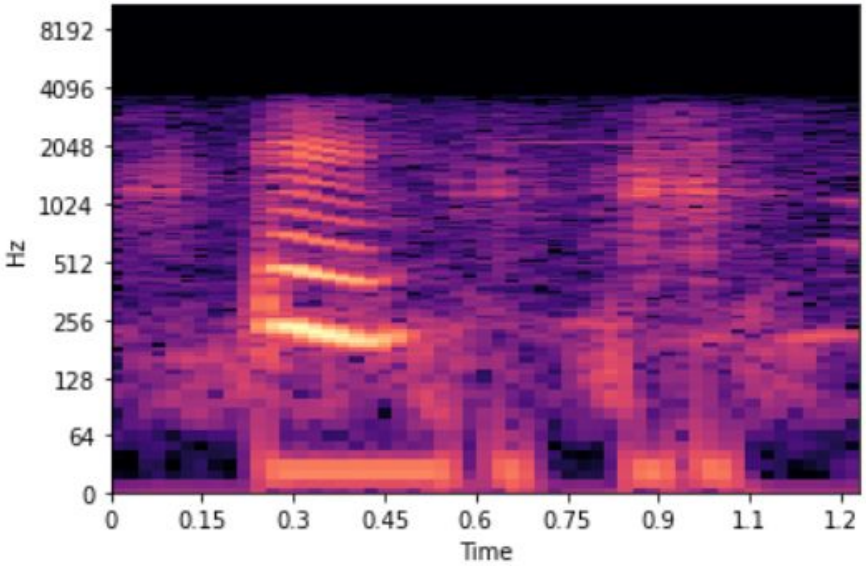

Представление аудио: mel spec

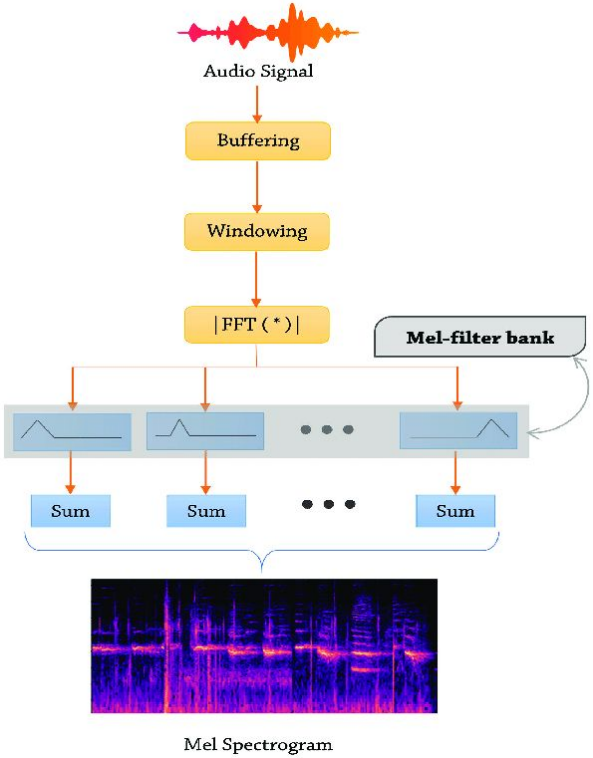

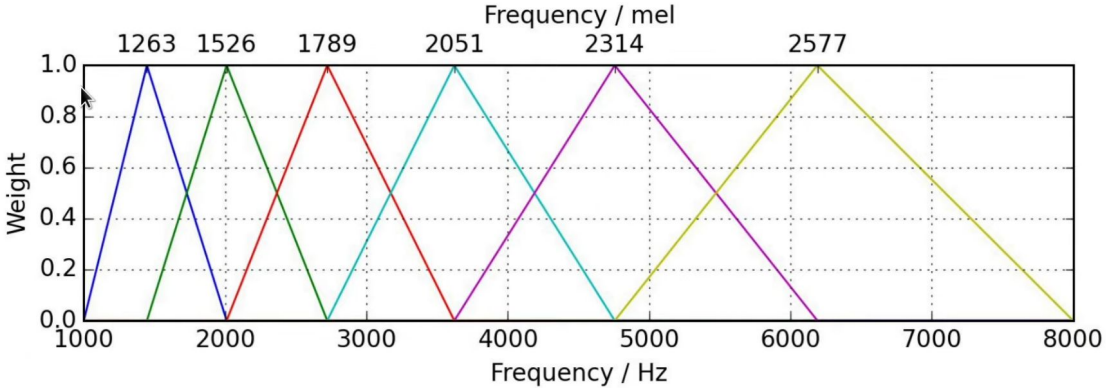

Представление аудио: MFCC

MFCC – Mel-frequency cepstral coefficients – моделируют особенности человеческого восприятия звука, в частности то, как ухо воспринимает частоты: человек воспринимает звуки на логарифмической шкале частот

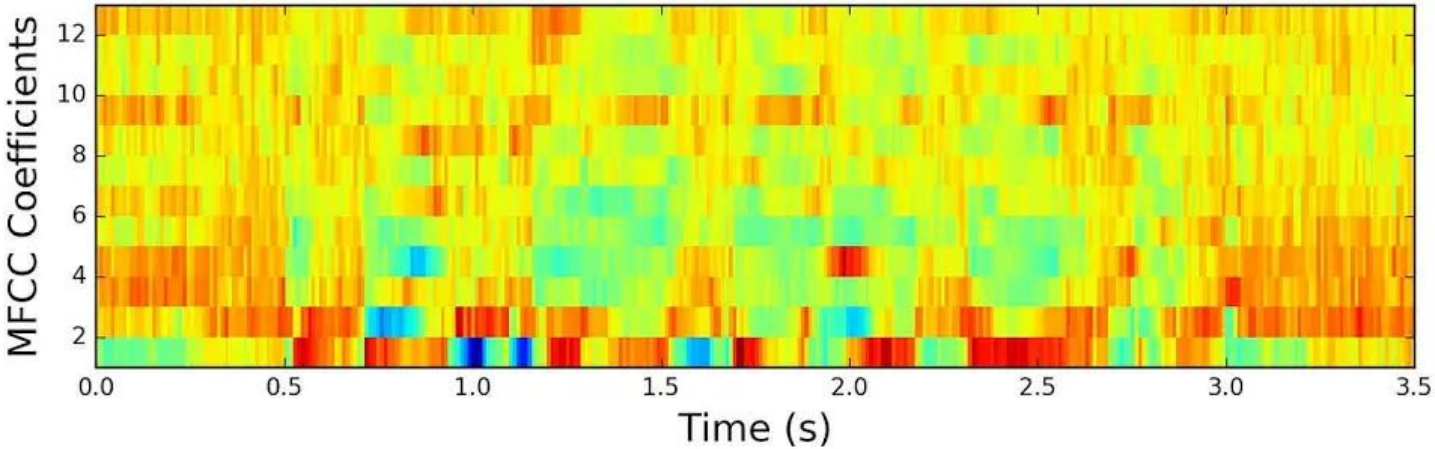

Представление аудио: MFCC

Алгоритм:

1. К сигналу применяется дискретное преобразование Фурье.
2. От полученного спектра мощности сигнала берется логарифм, чтобы получить лог-спектр.
3. На лог-спектр накладывается банк мел-фильтров, что позволяет перейти к мел-спектрограмме.
4. К мел-спектру применяется прямое преобразование Фурье либо же дискретное косинусное преобразование (упрощенная версия преобразования Фурье).

Audio tagging

раздел 2

Audio tagging/classification

Audio tagging – это задача автоматического определения и присвоения меток (тегов) аудиофрагменту на основе его содержания.

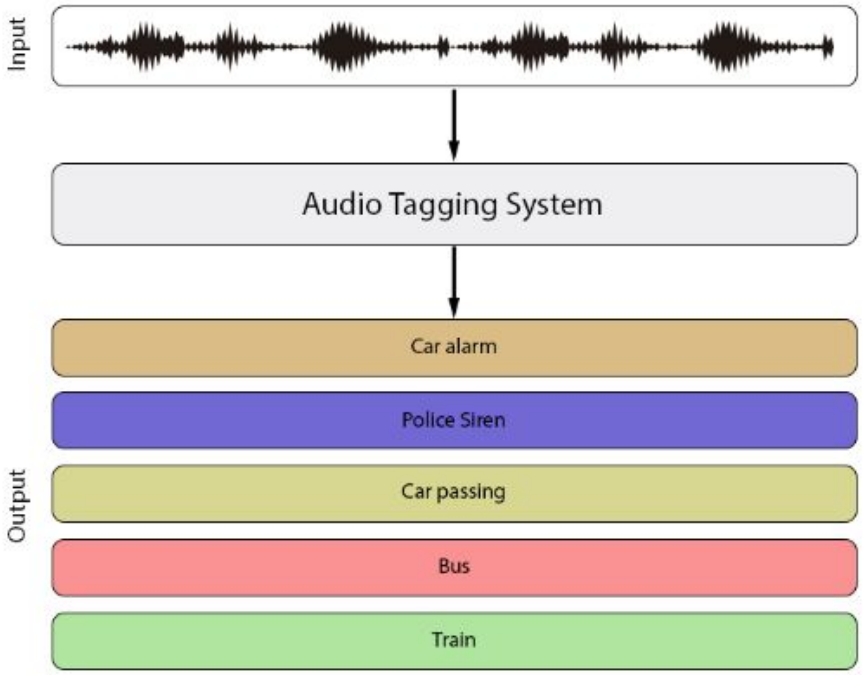

Audio tagging: CNN

CNN – convolution neural network

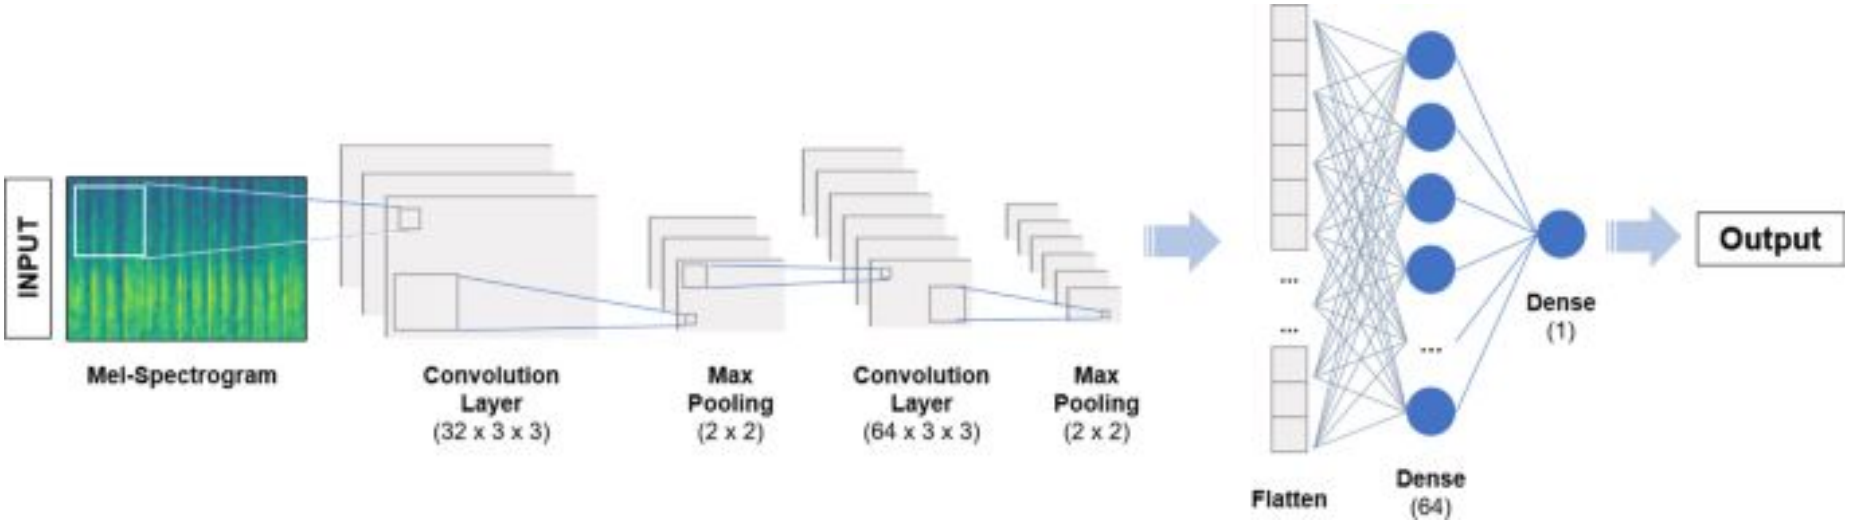

Audio tagging: Band Split

CNN + Band split

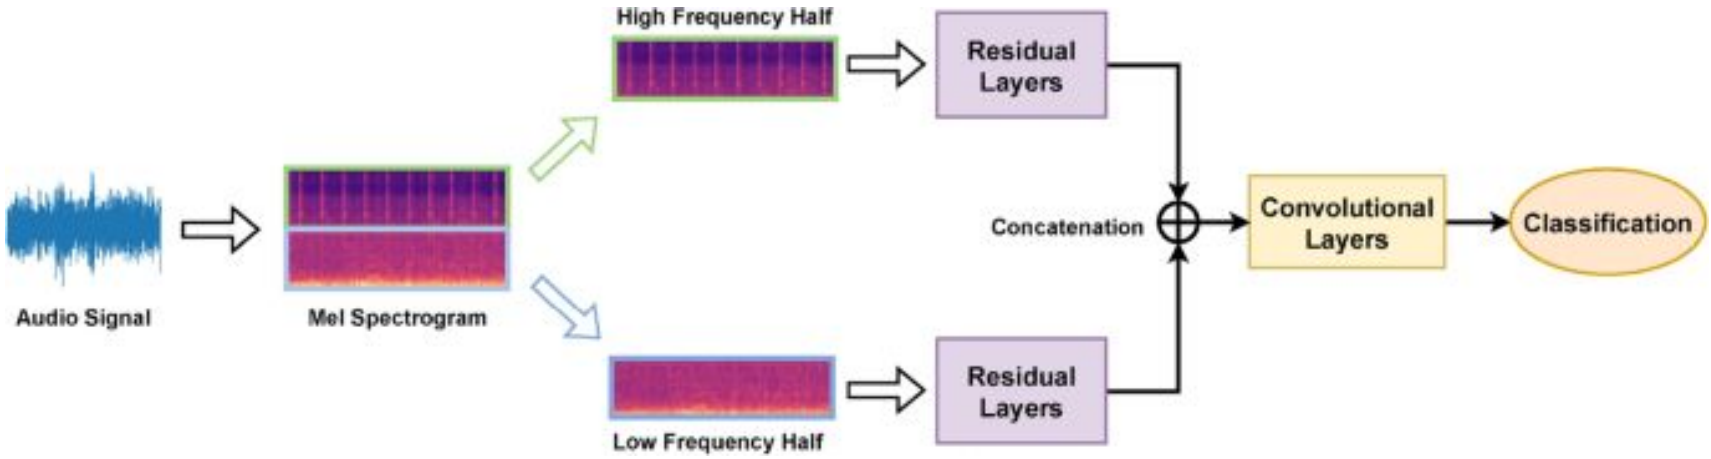

Audio tagging: Transformer

Transformer

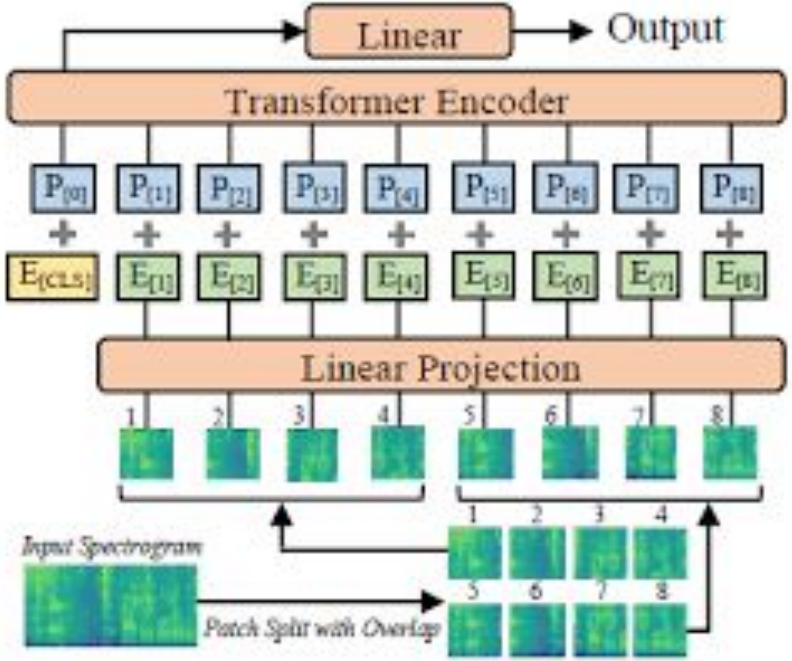

Audio tagging: Метрики

TP - Истинный положительный (True Positive)

FP - Ложное срабатывание (False Positive)

FN - Ложный отрицательный ответ (False Negative)

TN - Истинный отрицательный ответ (True Negative)

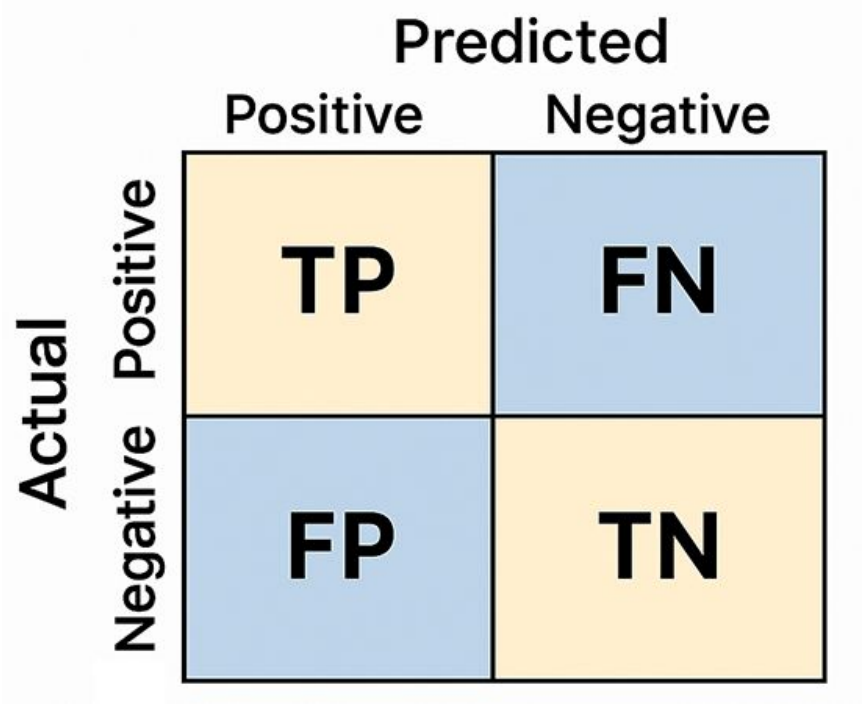

Audio tagging: Метрики

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Recall (or TPR)} = \frac{\text{correctly classified actual positives}}{\text{all actual positives}} = \frac{TP}{TP + FN} \quad (2)$$

$$\text{Precision} = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP} \quad (3)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (4)$$

Audio tagging: Метрики

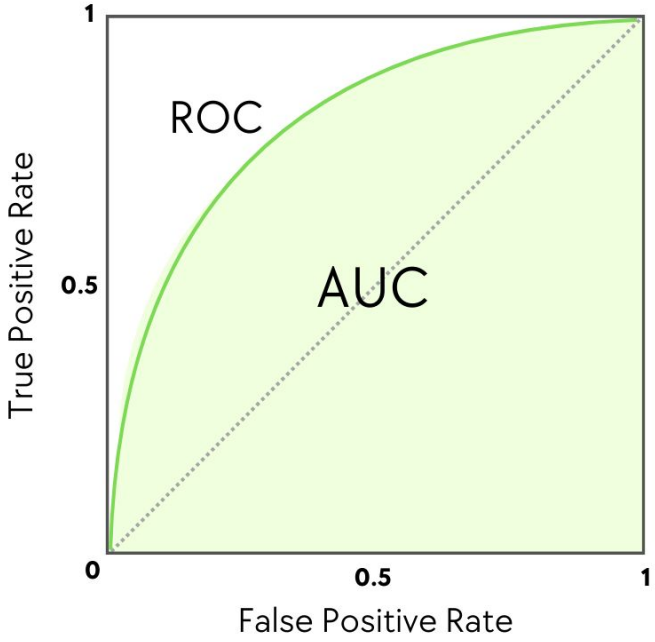

ROC-AUC

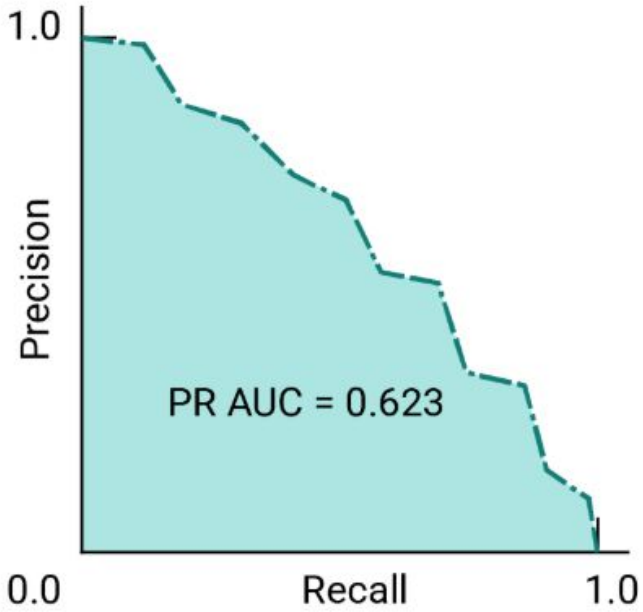

PR-AUC

Audio tagging: Метрики

$$mAP = \frac{1}{n}\sum_{k=1}^{k=n} AP_k$$

$$AP_k = \text{ the AP of class } k$$

$$n = \text{ the number of classes}$$

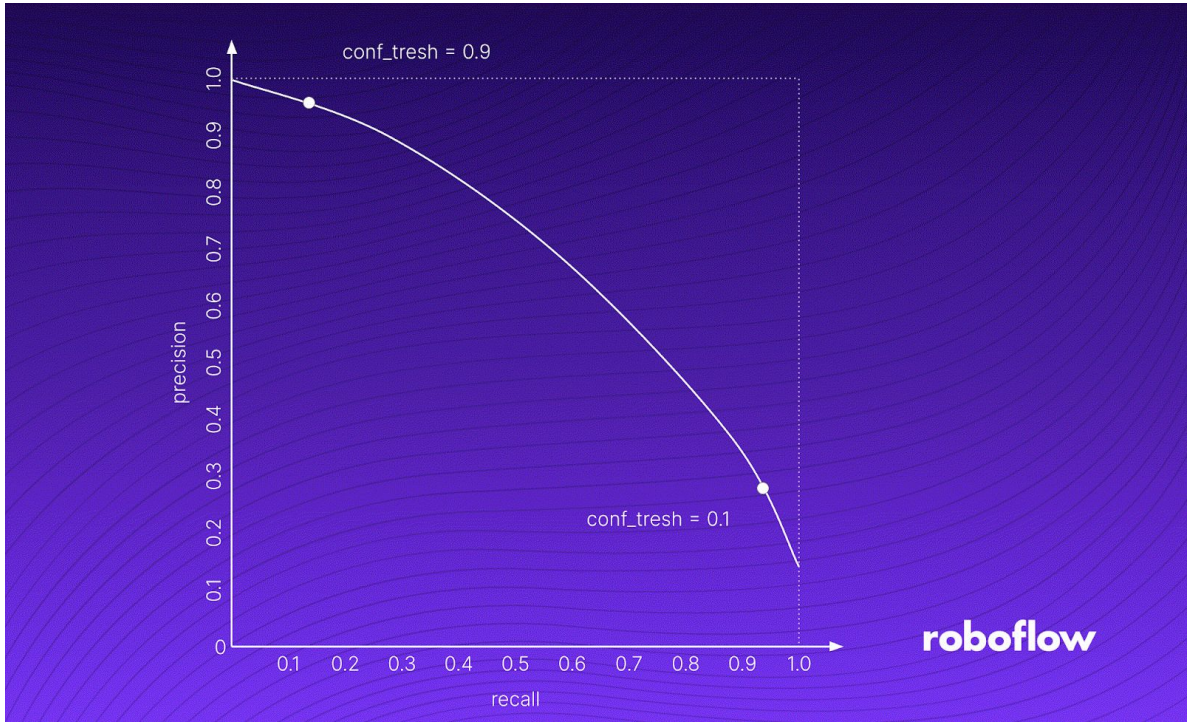

Audio tagging: Метрики

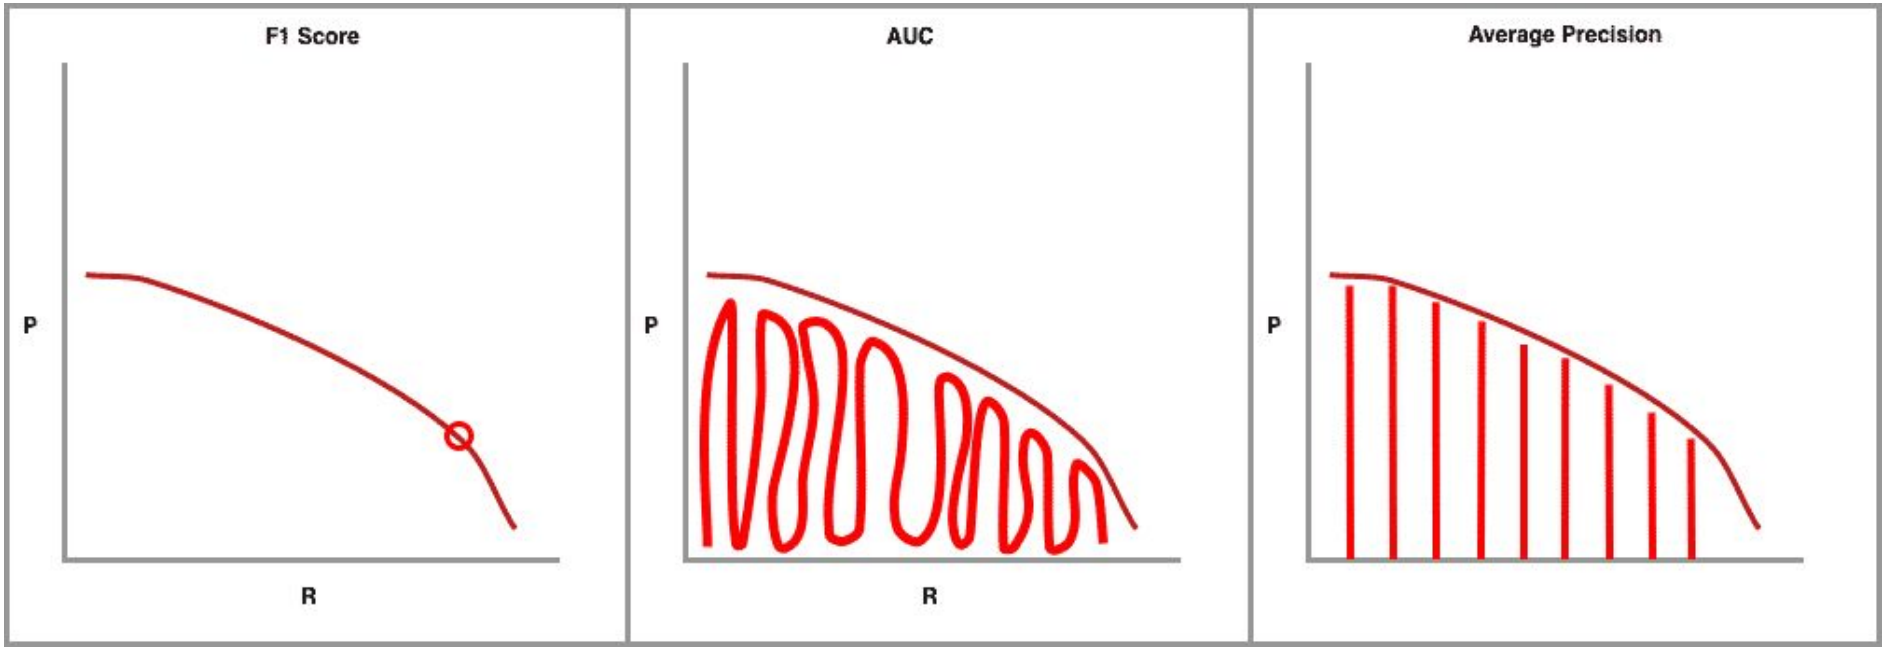

Audio tagging: Датасеты

Датасет	~Часов	kHz	Описание
AudioSet	5800	-	Мультимодальный аудио датасет YouTube
ESC-50	~5	44.1	50 классов экологических звуков
UrbanSound8K	~9	44.1	Городские звуки
FSDKaggle2019	~60	44.1	аудионабор данных, аннотированных 80 метками онтологии AudioSet

Speech enchancement

раздел 3

Speech enchancement

Speech enchancement – улучшение качества речи

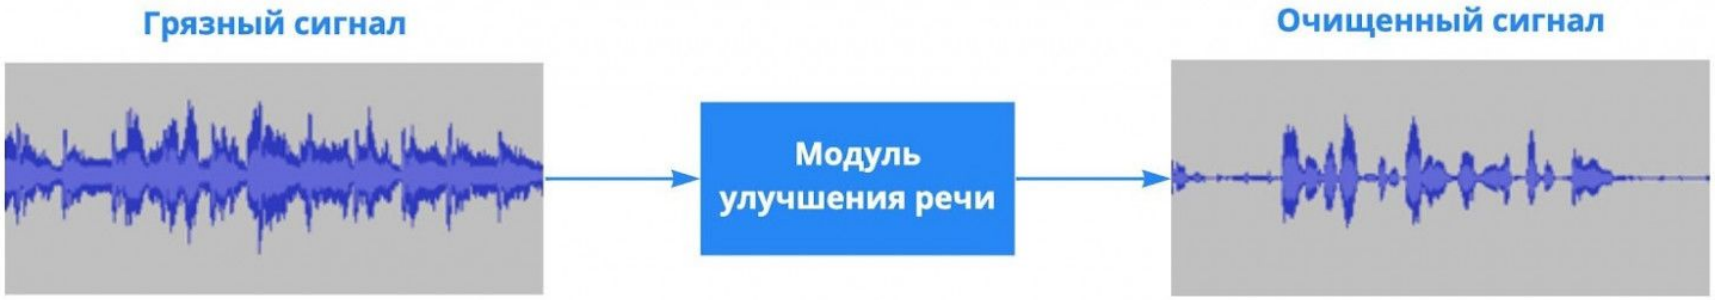

Speech enchancement: Метрики

Signal-to-Noise Ratio (SNR)

$$\mathrm{SNR} = \frac{P_{\mathrm{signal}}}{P_{\mathrm{noise}}} = \left(\frac{A_{\mathrm{signal}}}{A_{\mathrm{noise}}}\right)^2, \tag{1}$$

$$\mathrm{SNR}_{\mathrm{dB}} = 10\log_{10}\left(\frac{P_{\mathrm{signal}}}{P_{\mathrm{noise}}}\right). \tag{2}$$

Source-to-Distortion Ratio (SDR)

$$\mathrm{SDR} := 10\log_{10}\left(\frac{\|s_{\mathrm{target}}\|^2}{\|e_{\mathrm{interf}} + e_{\mathrm{noise}} + e_{\mathrm{artif}}\|^2}\right) \tag{3}$$

Speech enchancement: Метрики

MOS – mean opinion score

Просим людей оценить качество по пятибалльной шкале, затем усредняем оценки

$$MOS = \frac{\sum_{n=1}^{N} R_n}{N}$$

Rating	Label
5	Excellent
4	Good
3	Fair
2	Poor
1	Bad

Speech enchancement: Метрики

Субъективные

+ Легко интерпретировать

+ Часто отражают действительность

- Не воспроизводятся

- Дорого в использовании

Объективные

+ Легко воспроизводятся

+ Дешевые и быстро считаются

– Частенько не отражают действительности

Speech enchancement: Метрики

NISQA - Non Intrusive Speech Quality Assessment

Оценивает 5 параметров:

- Noisiness
- Coloration
- Discontinuity
- Loudness
- MOS

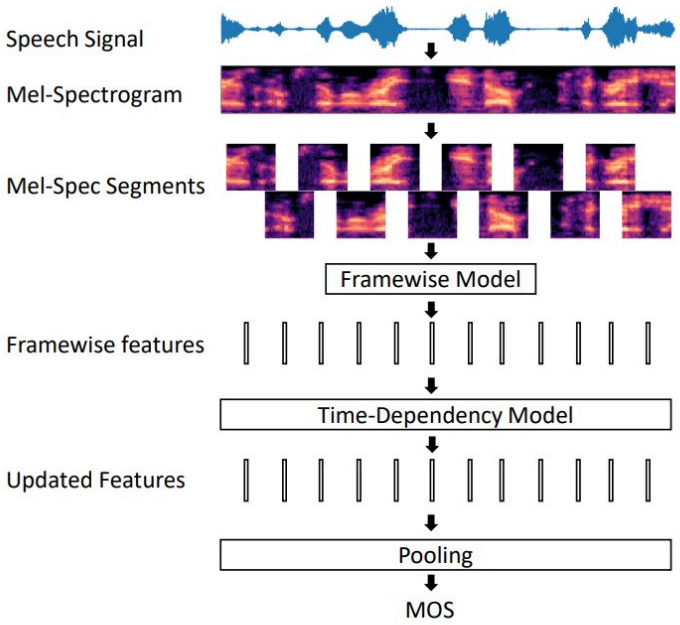

Figure 1: *General speech quality model structure.*

https://www.isca-speech.org/archive/pdfs/interspeech_2021/mittag21_interspeech.pdf

Speech enchancement: Датасеты

Датасет	~Часов	kHz	Описание
DEMAND	~36 часов	48-16	База данных записей окружающего шума
Musan	~100 часов	16	Корпус музыки, речи и шума
LibreeSpeech	~960 часов	16	корпус английской речи
VCTK	~44 часов	48	корпус английской речи

Automatic speech recognition

раздел 4

Automatic speech recognition

Automatic speech recognition (ASR) – преобразования человеческой речи в текст

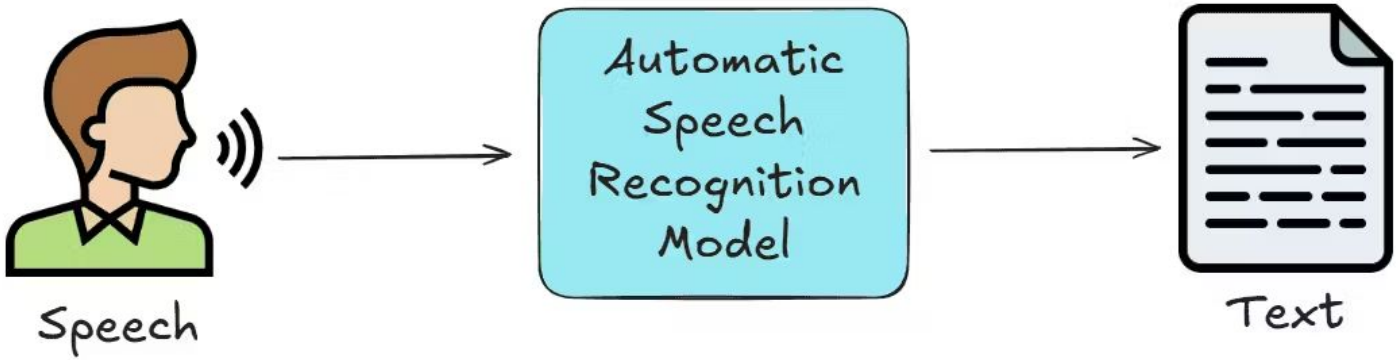

ASR: Whisper

Whisper – это модель на основе трансформера с encoder-decoder, также называемая моделью sequence-to-sequence

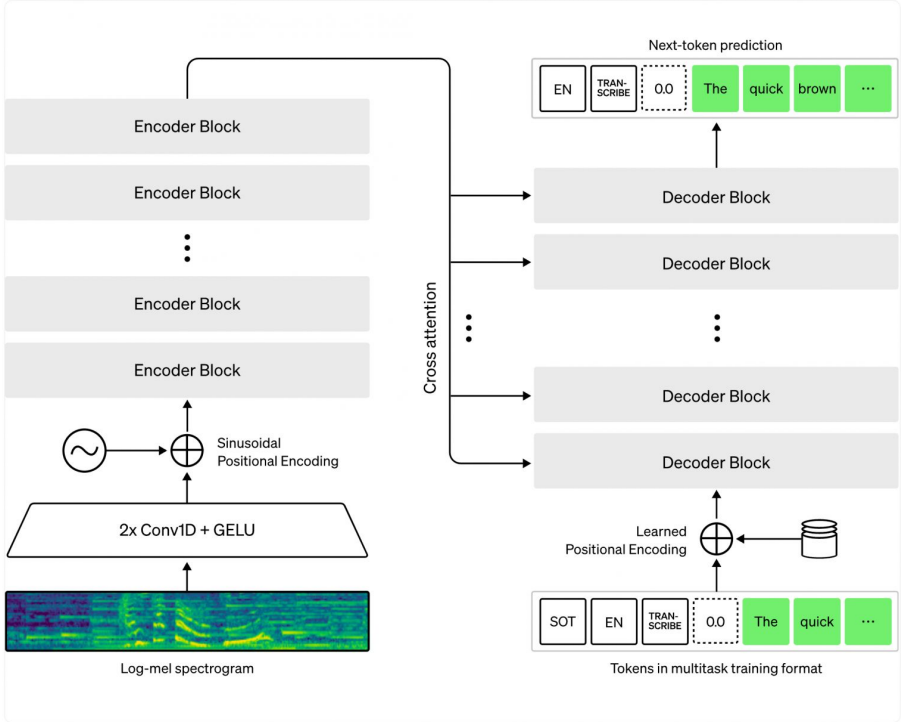

ASR: Whisper

Whisper

Size	Layers	Width	Heads	Parameters	English-only	Multilingual
tiny	4	384	6	39 M	✓	✓
base	6	512	8	74 M	✓	✓
small	12	768	12	244 M	✓	✓
medium	24	1024	16	769 M	✓	✓
large	32	1280	20	1550 M	x	✓

ASR: Wav2Vec

Wav2Vec

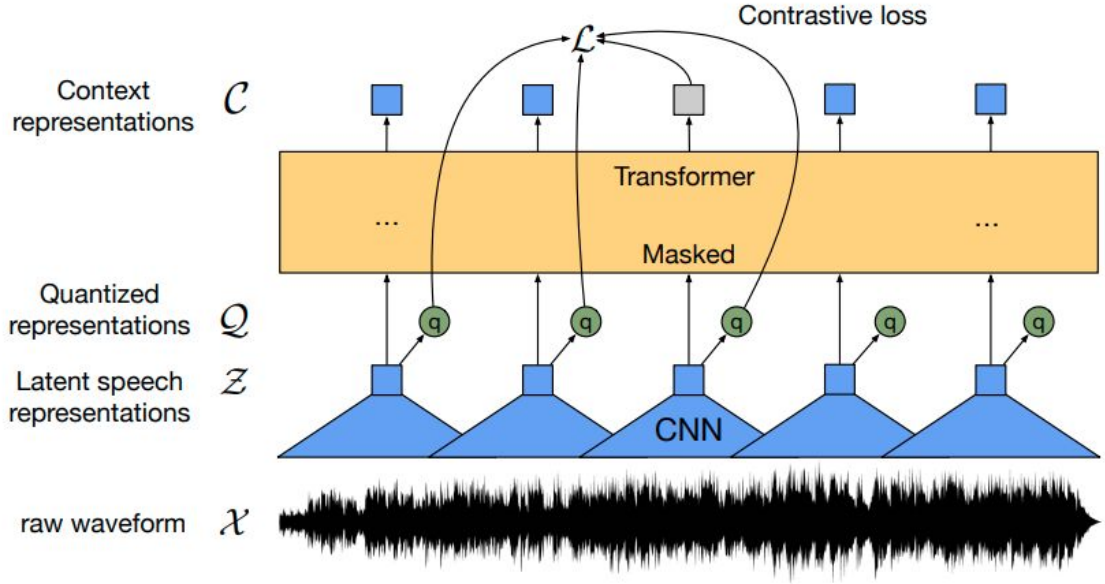

ASR: Метрики

Word Error Rate — доля (процент) неправильно распознанных слов

$$WER = \frac{S + D + I}{N}$$

Insertions (I) – Количество слов в гипотезе, которые не совпадают с соответствующими словами в эталоне.

Substitutions (S) – Количество слов в эталоне, которые отсутствуют в гипотезе.

Deletions (D) – Количество слов в гипотезе, которых нет в эталоне.

Number of words in the reference (N) – Общее число слов в правильной (эталонной) последовательности.

ASR: Пример

Эталон: кот спит дома → N = 3
Гипотеза: пёс спит
S=1 («кот»→«пёс»),
D=1 («дома» пропущено),
I=0
WER = (1 + 1 + 0) / 3 = 2/3 ≈ 0.67 или 67%

ASR: Датасеты

Датасет	~Часов	kHz	Описание
LibreeSpeech	~960 часов	16	корпус английской речи
AISHELL (для китайского)	~178	16	корпус китайской речи
Kazakh Speech Corpus	330	48	корпус казахской речи
ASR Sova	101	16	корпус русской речи

Speech synthesis

раздел 5

Speech synthesis (TTS)

Speech synthesis – преобразование текста в человеческую речь

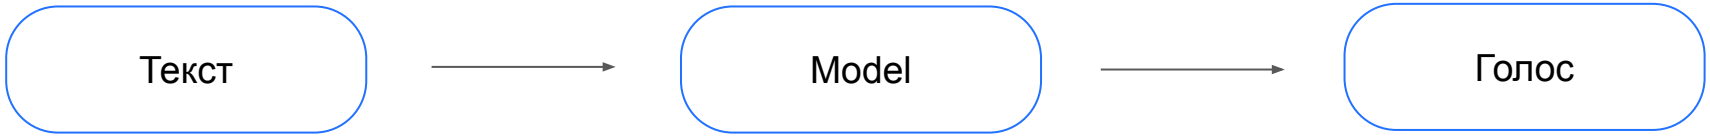

TTS: Tacotron

Tacotron2

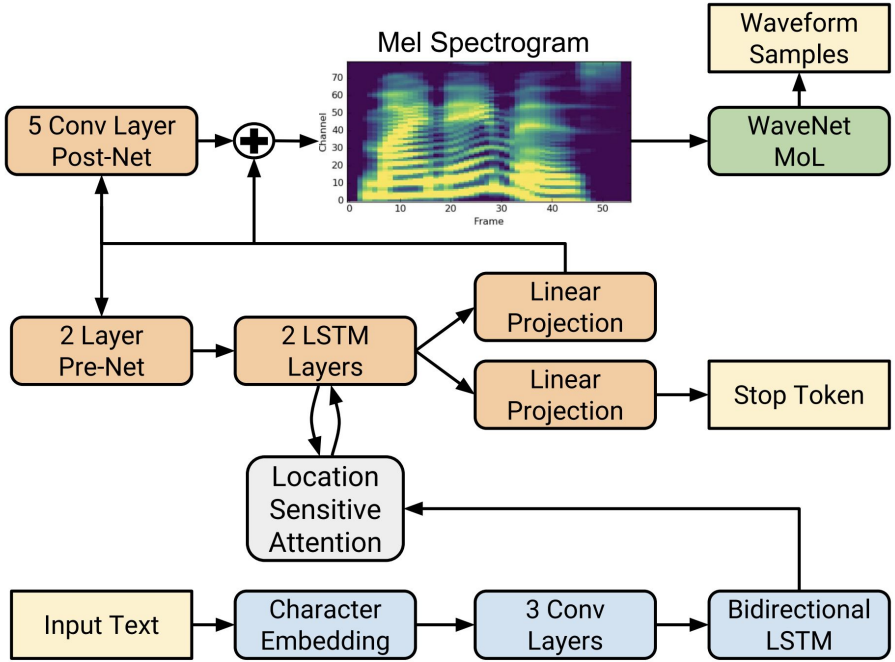

TTS: VALL-E

VALL–E

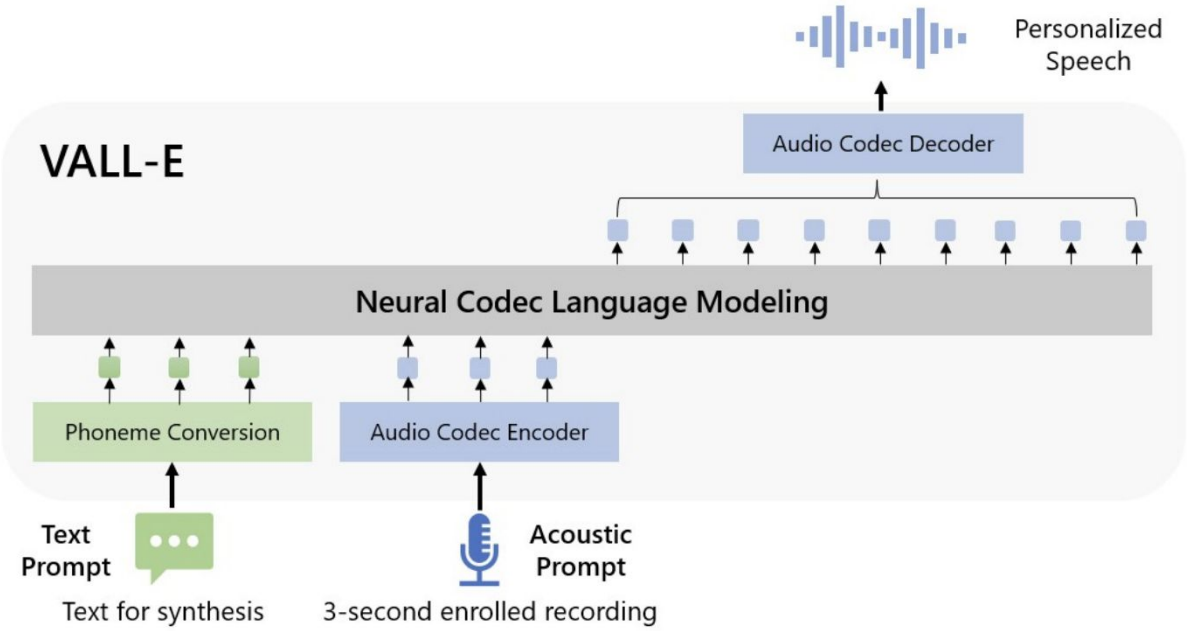

TTS: Метрики

MOS – mean opinion score

Просим людей оценить качество по пятибалльной шкале, затем усредняем оценки

$$MOS = \frac{\sum_{n=1}^{N} R_n}{N}$$

Rating	Label
5	Excellent
4	Good
3	Fair
2	Poor
1	Bad

TTS: Метрики

MUSHRA – как MOS,
но шкала более
гранулированная:
от 0 до 100

Показываем сразу
несколько семплов

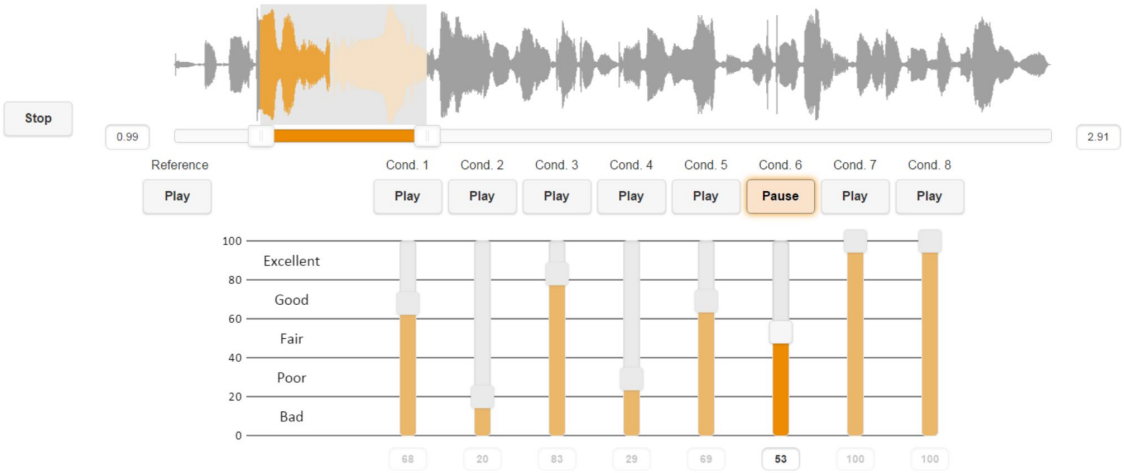

TTS: Метрики

Side-by-Side сравнение (SBS) – *доля выбранных примеров тестируемой модели* в попарных сравнениях против бейзлайна

TTS: Датасеты

Датасет	~Часов	kHz	Описание
LJ Speech	24	22	13 100 коротких аудио, в которых один и тот же диктор читает отрывки из 7 научно-популярных книг.
VCTK	~44 часов	48	корпус английской речи
LibriTTS	1,000	24	создан на основе оригинальных корпуса LibriSpeech
Ruslan	31	44	Single-speaker TTS
LibriHeavy	50,000	16	корпус английской речи Multi-Speaker TTS

Практика

Итоги занятия

1. Узнали основные задачи Audio ML
2. Рассмотрели основные метрики
3. Поняли в чем различие субъективной от объективной метрики
4. Попробовали обучить классификатор

Дополнительные материалы

Визуализация метрики ROC-AUC

Симулятор ротовой полости

Библиотека с метриками (torch)

Официальная документация PyTorch

Официальная документация Librosa

Ссылка на репозиторий Nisqa-s

Ссылка на репозиторий Nisqa

На следующем занятии

1. Рассмотрим задачу speech enchancement
2. Попробуем обучить шумодав)

Спасибо за внимание!

Рефлексия

- Что теперь смогу использовать в работе?
- Что изменилось? Раньше я думал(а), что…, а теперь…
- Какие вопросы у меня остались?