ИНЖЕНЕРНО-
МАТЕМАТИЧЕСКАЯ
ШКОЛА
НИУ ВШЭ И VK

Введение в синтез речи

education

ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ

Сиротинский Никита

- Аспирант МИЭМ на направление “Системный анализ и математическое моделирование”

Сегодня на занятии

1. История
2. Постановка задачи
3. Общая классификация
4. Классические подходы
5. Метрики

История

раздел 1

История

- 1779 год - механического устройства, способного издавать пять долгих гласных звуков: а, э, и, о, у - Христиан Готлиб Кратценштейн
- 1791 год - машина, моделирующая речевой тракт человека - Вольфганг фон Кемпелен
- 1850 год - резонаторная теория - Герман фон Гельмгольц
- Начало XX века - реализация резонаторной теории в виде простого синтезатора - Джон Стюарт
- 1930 год - разработка вокодера и системы VODER - Гомер Дадли из Bell Laboratories

История

- 1946 год - акустический спектрограф - первый синтезатор на основе спектрограммы - Л. Шотт (Bell Labs)
- 1963 год - аналоговый компьютер на основе лестничной логики - японцы (ETL и Hitachi)
- 1974 год - Дональд Шерман использовал Votrax для заказа пиццы по телефону
- 1976 год - «читающая машина» - Рэймонд Курцвейл
- 1976 год - «говорящий» калькулятор — LPC Speech+
- 1978 год - детская игрушка Speak & Spell - Texas Instruments

История

- 1981-1984 год - DECtalk - первый конкатенативный алгоритм синтеза речи
- 1982 год - S.A.M. - Марк Бартон
- 2010 год - первые нейросетевые алгоритмы
- 2016 год - WaveNet

Постановка задачи

раздел 2

Задача синтеза речи

Приведение текстовый данных к аудио-сигналу

Обрабатываемые данные

- Текстовые данные
- Сырые волновые формы
- Спектрограммы
- Мелспектрограммы
- Encodec и другие специализированные представления

Проблема №1

Аудио имеет высокую частоту сигнала, что не позволяет обычным нейросетевым моделям нормально обучаться на таких данных.

Решение

Будем обрабатывать сжатые представления с меньшей размерностью, из которых впоследствии восстановим аудиосигнал.

Спектрограмма

- Оконная функция
- Преобразование Фурье

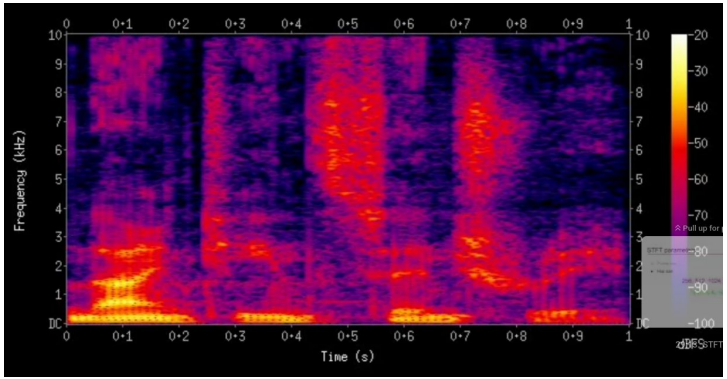

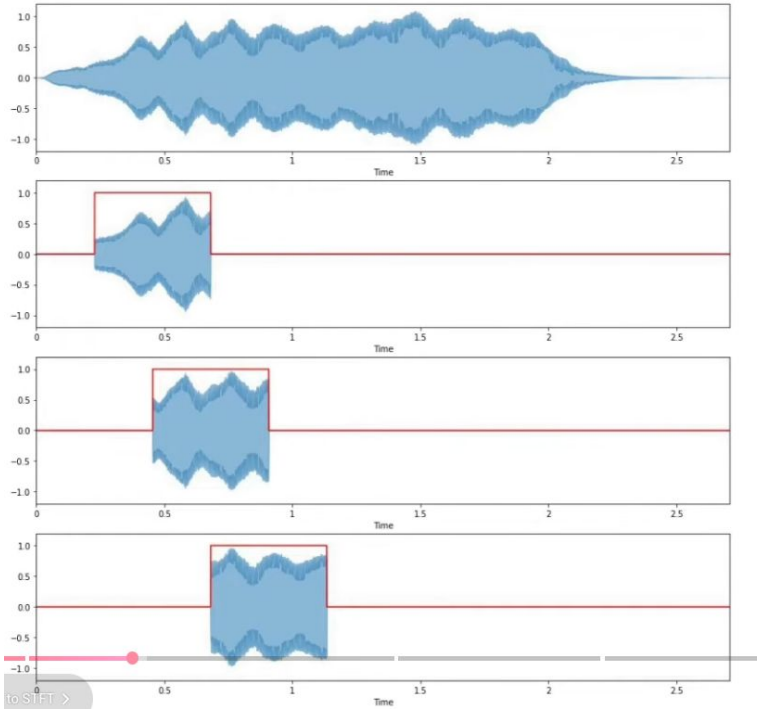

Мелспектрограмма

- Мел-шкала

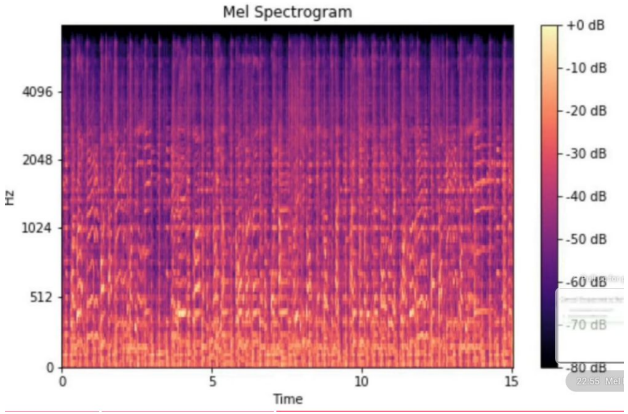

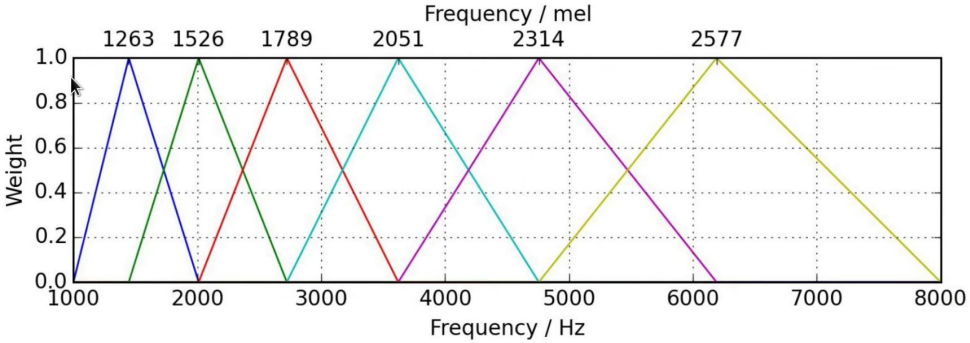

Мелспектрограмма

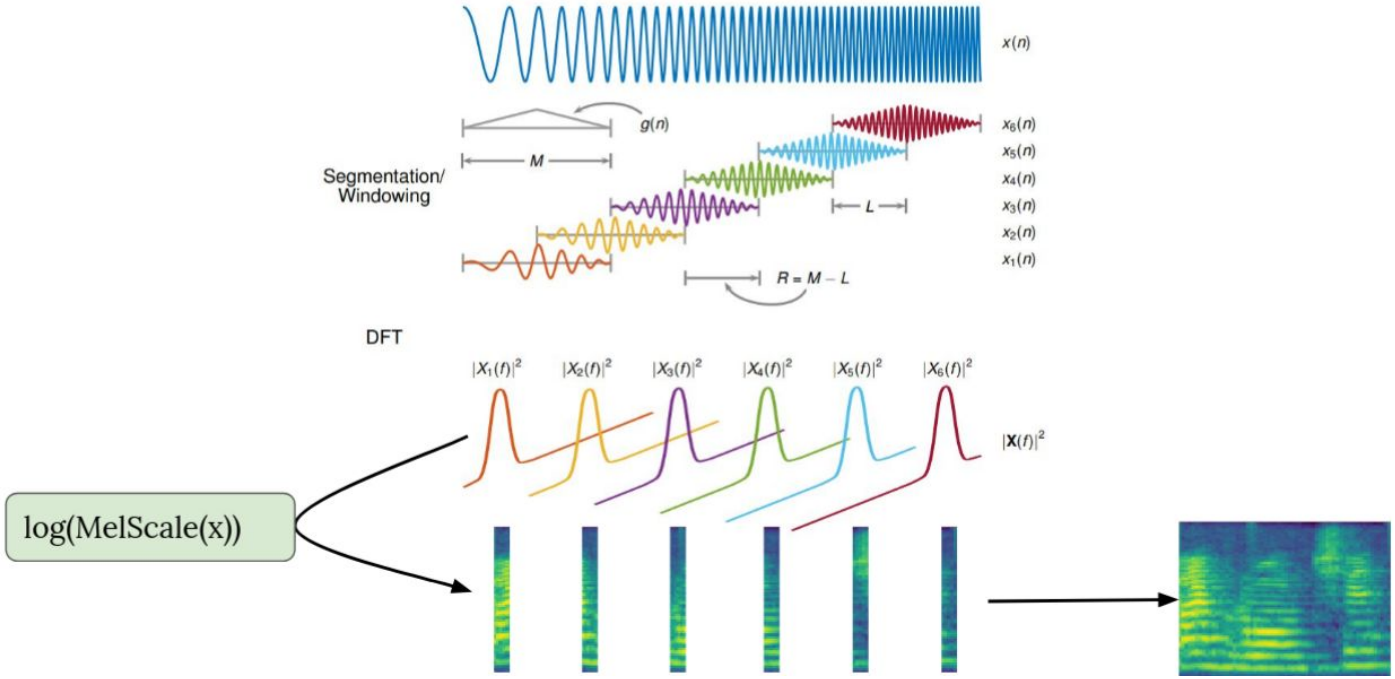

Проблема №2

Приведение аудио к мелспектрограмме необратимо.

Решение

Разделим синтез аудио на 2 этапа:

1. Модель, которая генерирует мел-спектрограммы из текста
2. Модель, которая восстанавливает исходный аудиосигнал из мелспектрограммы

Решение

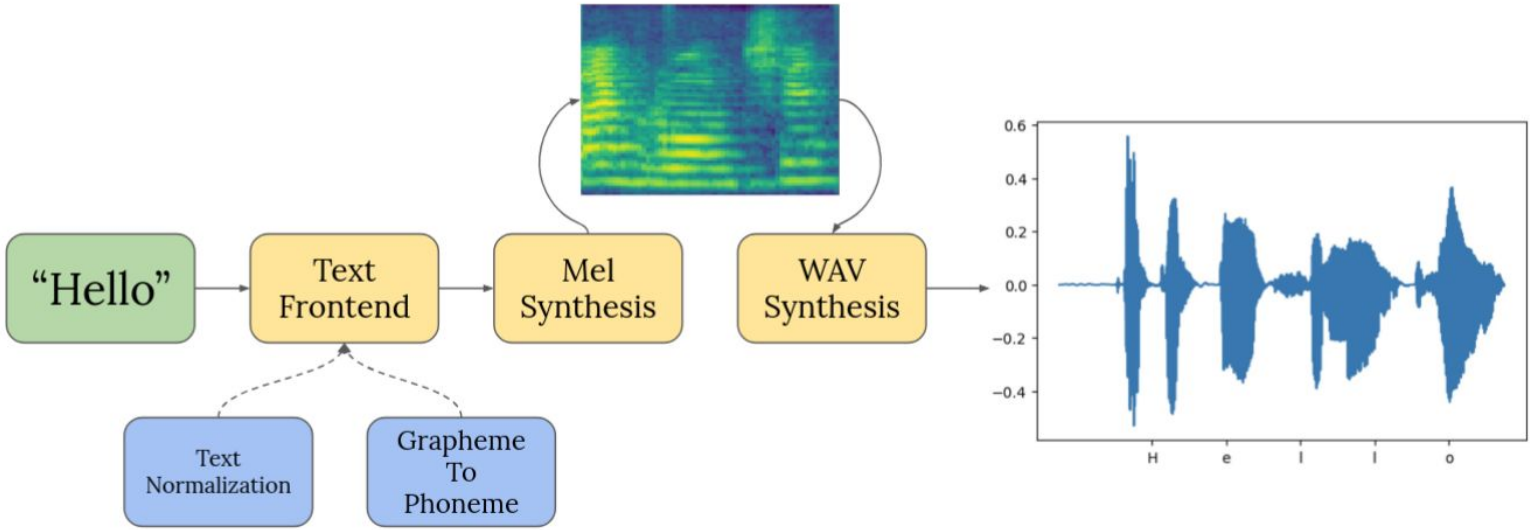
"Hello"
Text Frontend
Mel Synthesis
WAV Synthesis
Text Normalization
Grapheme To Phoneme
0.6
0.4
0.2
0.0
−0.2
−0.4
H
e
l
l
o

Классификация

раздел 3

Классификация

- По типу генерации:
  - Авторегессионные модели
  - Не-авторегессионные модели
- По способам генерации:
  - Many-shot
  - Few-shot
  - Zero-shot
- По базовой архитектуре
  - RNN
  - GAN
  - Потоки
  - Диффузионные модели
- Акустическая модель + вокодер
- End-to-end

Классические подходы

раздел 4

Акустические модели

- Tacotron 2

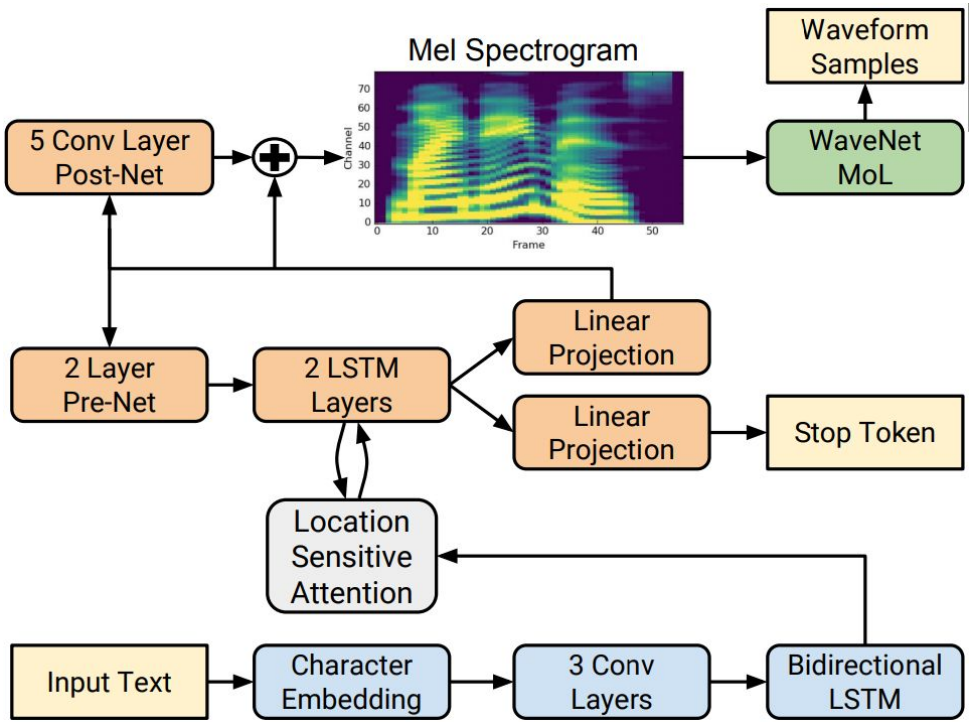

Акустические модели

- FastSpeech

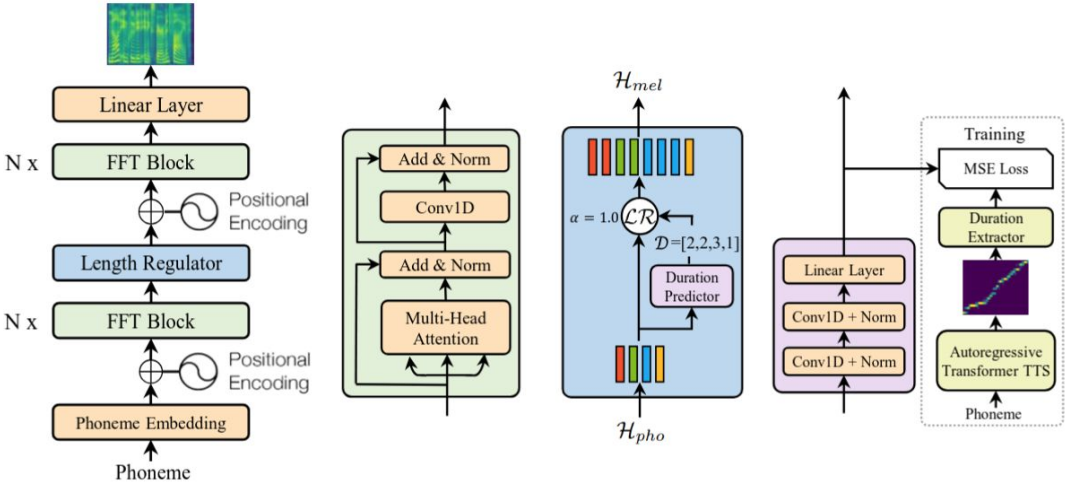

Вокодеры

- Граффин Лим

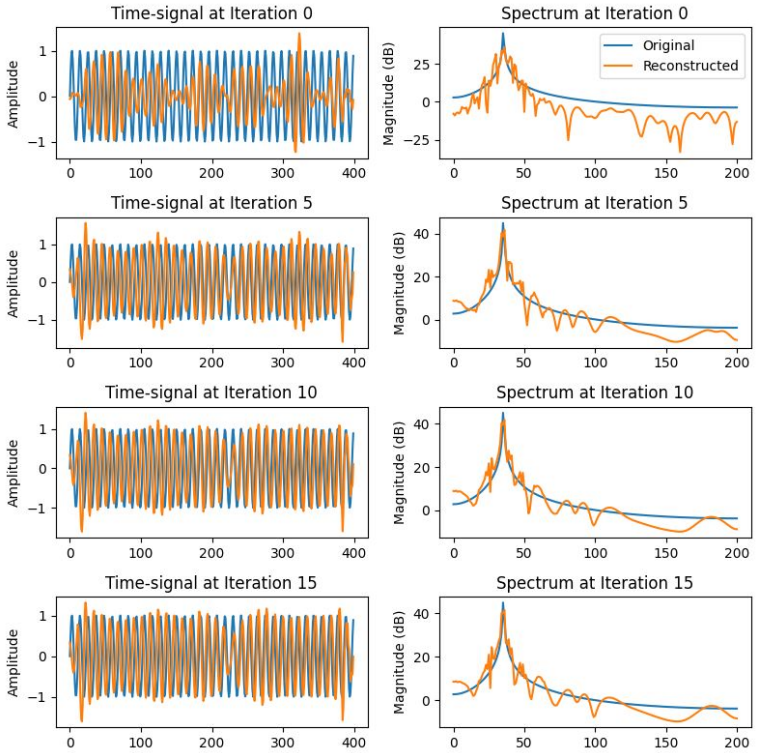

https://speechprocessingbook.aalto.fi/Modelling/griffinlim.html

Вокодеры

- WaveNet

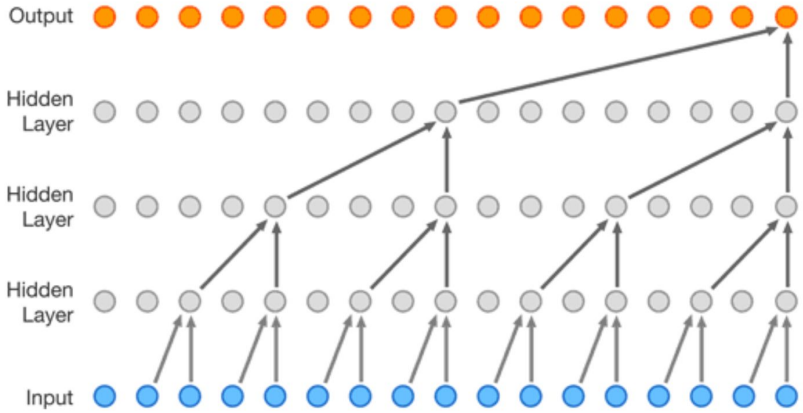

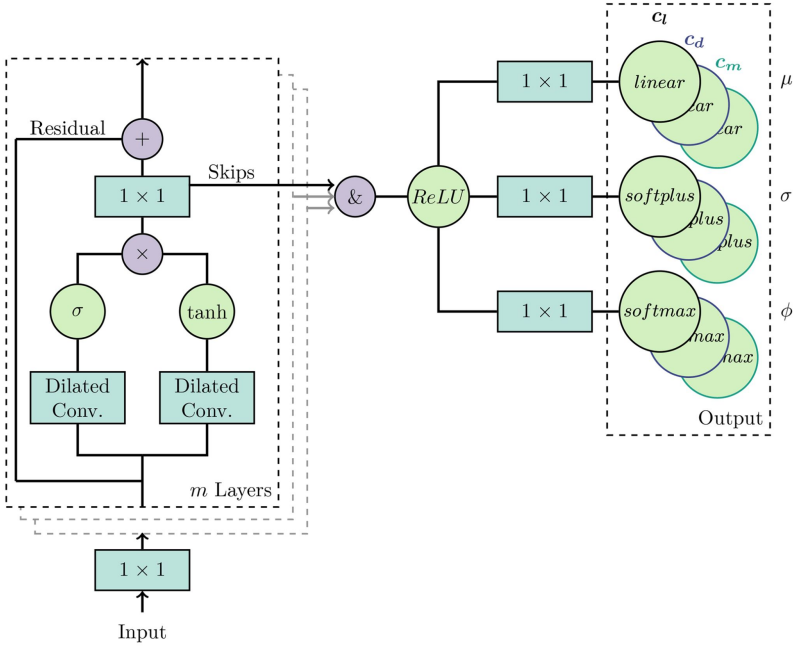

Вокодеры

- HifiGAN

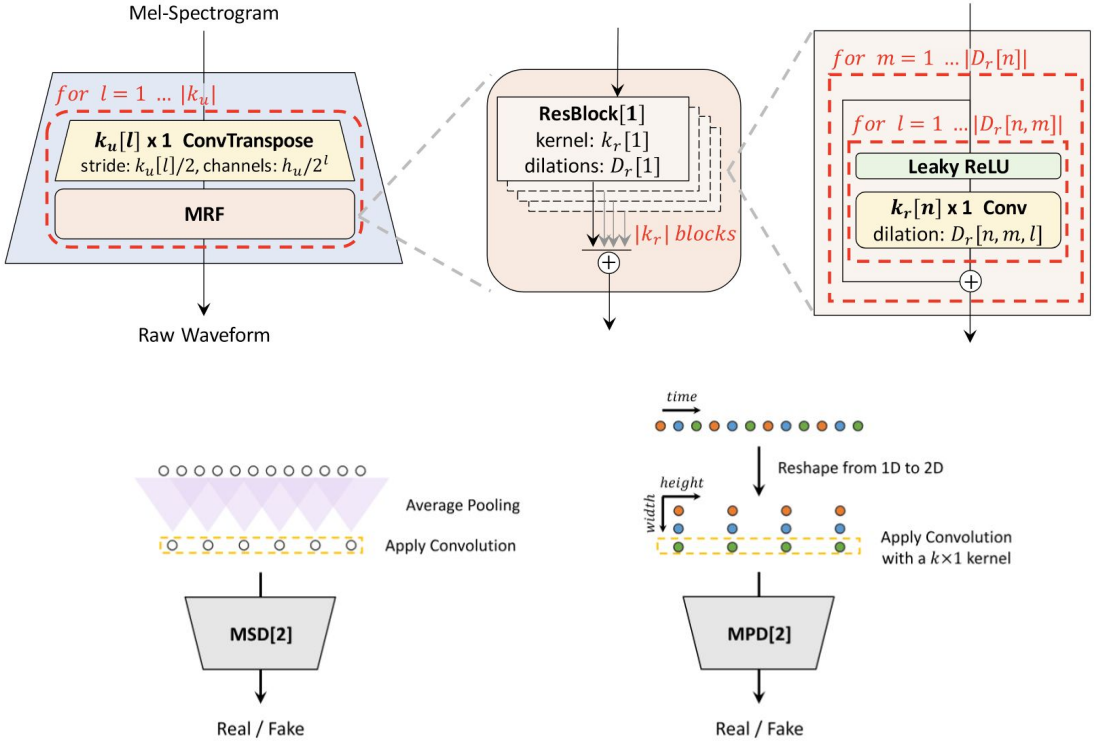

Метрики

раздел 5

Метрики

- Оценить объективно качество речи сложно
- Лучше использовать метрику MOS (mean opinion score)
- CosSim для оценки похожести голоса
- WER

Проблема MOS

- Сложно и долго проводить
- Будем использовать нейросетевую модель
  - Torchaudio SQUIM
  - DNSMOS
  - U-MOS

Cosine similarity

- Показывает близость векторов

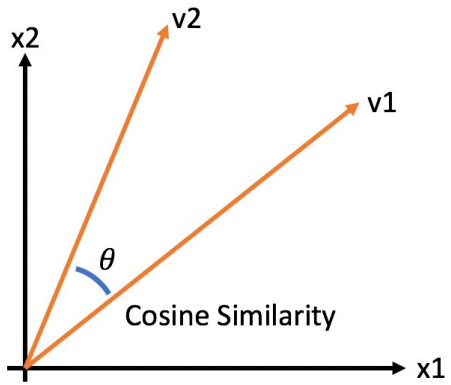

WER

- Будем использовать ASR модель для преобразования синтетической речи обратно в текст
- Показывает “разборчивость” речи

$$WER = \frac{S + D + I}{N} = \frac{S + D + I}{S + D + C}$$

where

- S is the number of substitutions,
- D is the number of deletions,
- I is the number of insertions,
- C is the number of correct words,
- N is the number of words in the reference (N=S+D+C)

Выводы

раздел 6

Выводы

- История задачи синтеза речи очень длинная
- В последние годы используются различные нейросетевые модели
- В основе многих современных подходов лежит применение различных сжатых представлений, в частности, мел-спектрограмм
- Оценить качество синтезированной речи сложно

Домашнее задание

Домашнее задание

В домашней работе проверяется умение применять модели синтеза на примере Tacotron2, а также базовое понимание механизма внимания и влияние на выравнивание между входным текстом и выходным аудио.

Спасибо за внимание!