ИНЖЕНЕРНО-
МАТЕМАТИЧЕСКАЯ
ШКОЛА
НИУ ВШЭ И VK

Введение в синтез речи

education

ВЫСШАЯ • ШКОЛА • ЭКОНОМИКИ

Сиротинский Никита

- Аспирант МИЭМ на направление “Системный анализ и математическое моделирование”

Сегодня на занятии

1. Непрерывные модели
2. Модели на кодеках
3. Перенос особенностей речи
4. Выводы

Непрерывные модели

раздел 1

Особенность старых моделей

- Используем мел-спектрограммы как сжатое представление звука
- Пытаемся заставить нейронную сеть “подстроиться” под это представление

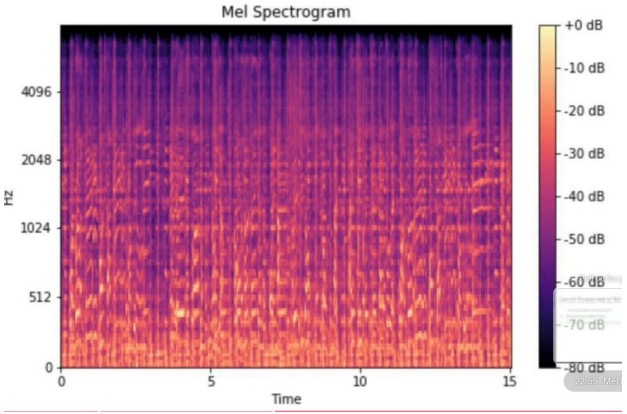

Раздельный подход к синтезу

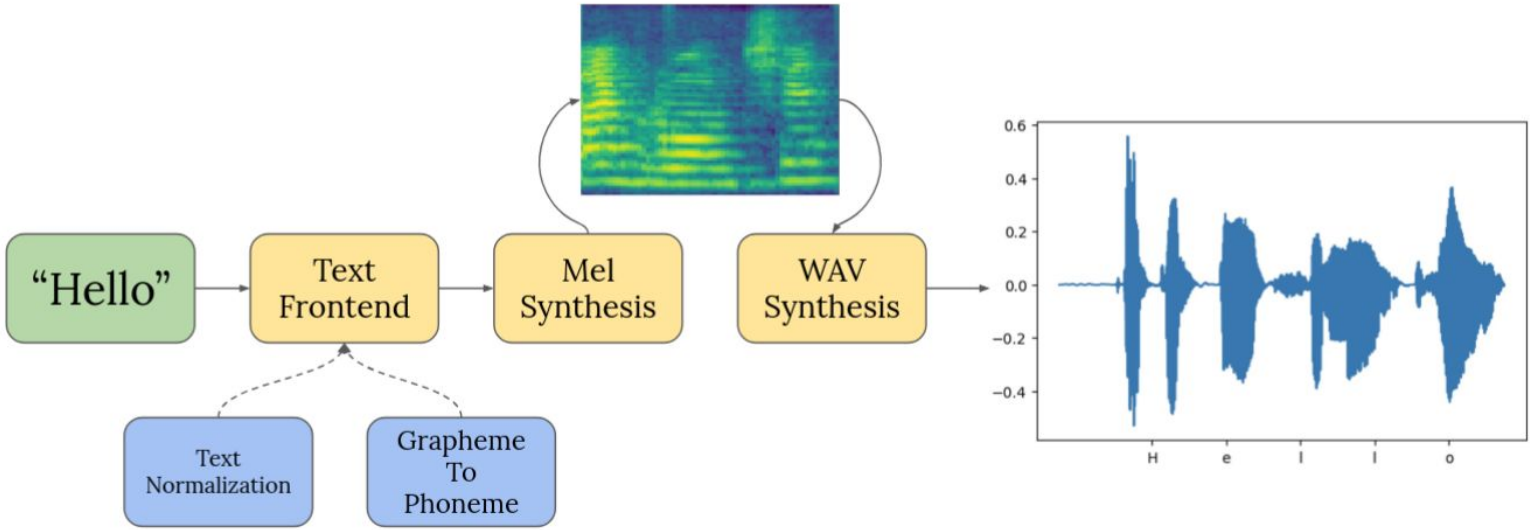

Непрерывный подход

- Объединим акустическую модель и вокодер в одну модель
- Позволим модели выучить произвольное сжатое представление для звука

VITS

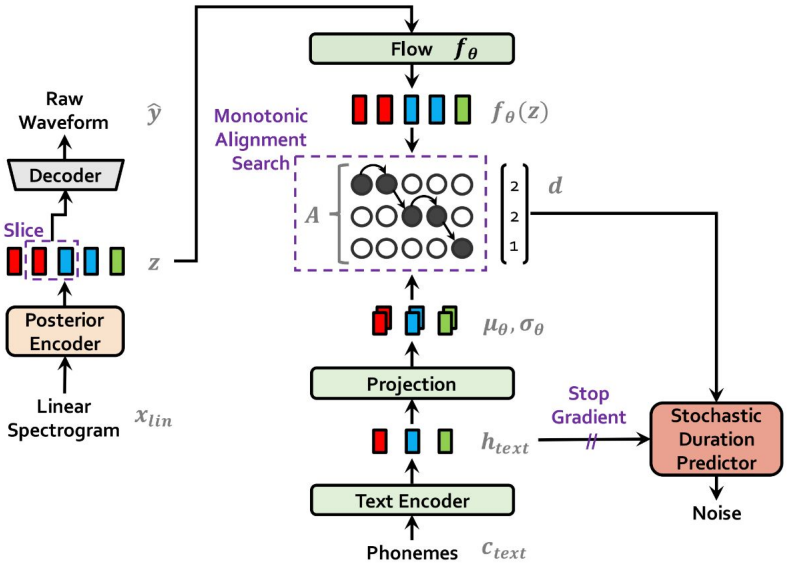

(a) Training procedure

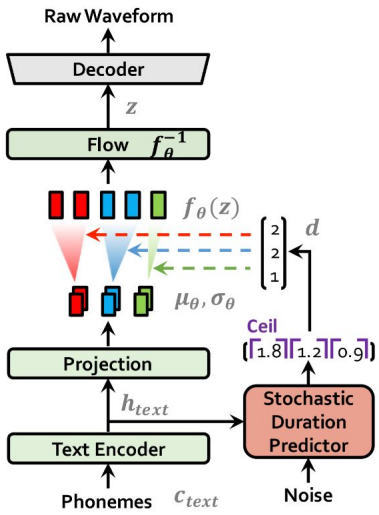

(b) Inference procedure

Monotonic Alignment Search

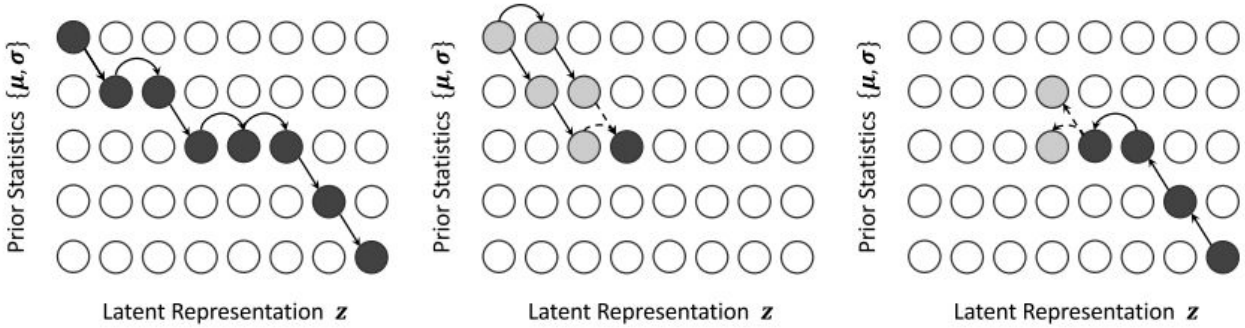

(a) An example of monotonic alignments

(b) Calculating the maximum log-likelihood Q.

(c) Backtracking the most probable alignment A^*.

Figure 2: Illustrations of the monotonic alignment search.

Модели на кодеках

раздел 2

EnCodec

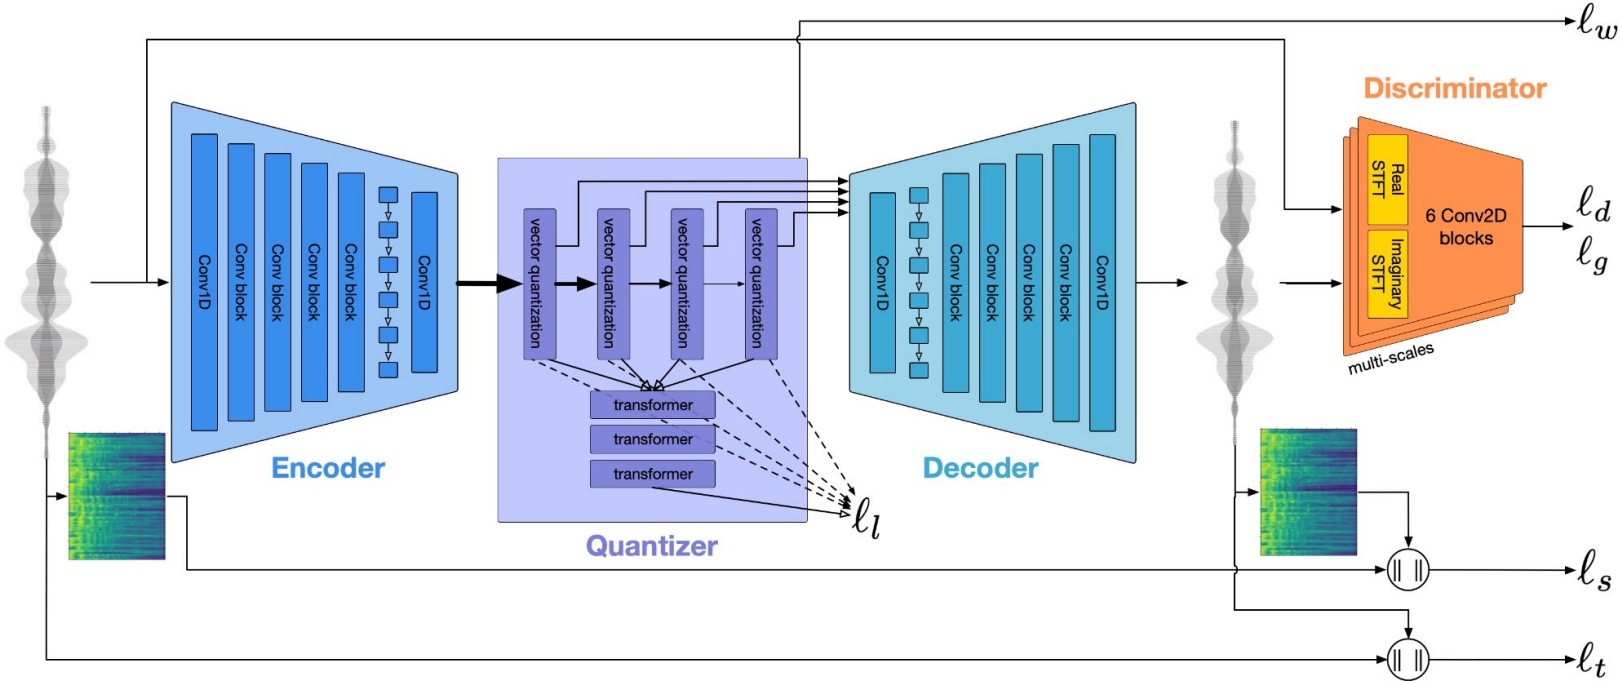

https://arxiv.org/pdf/2210.13438

Vall-E

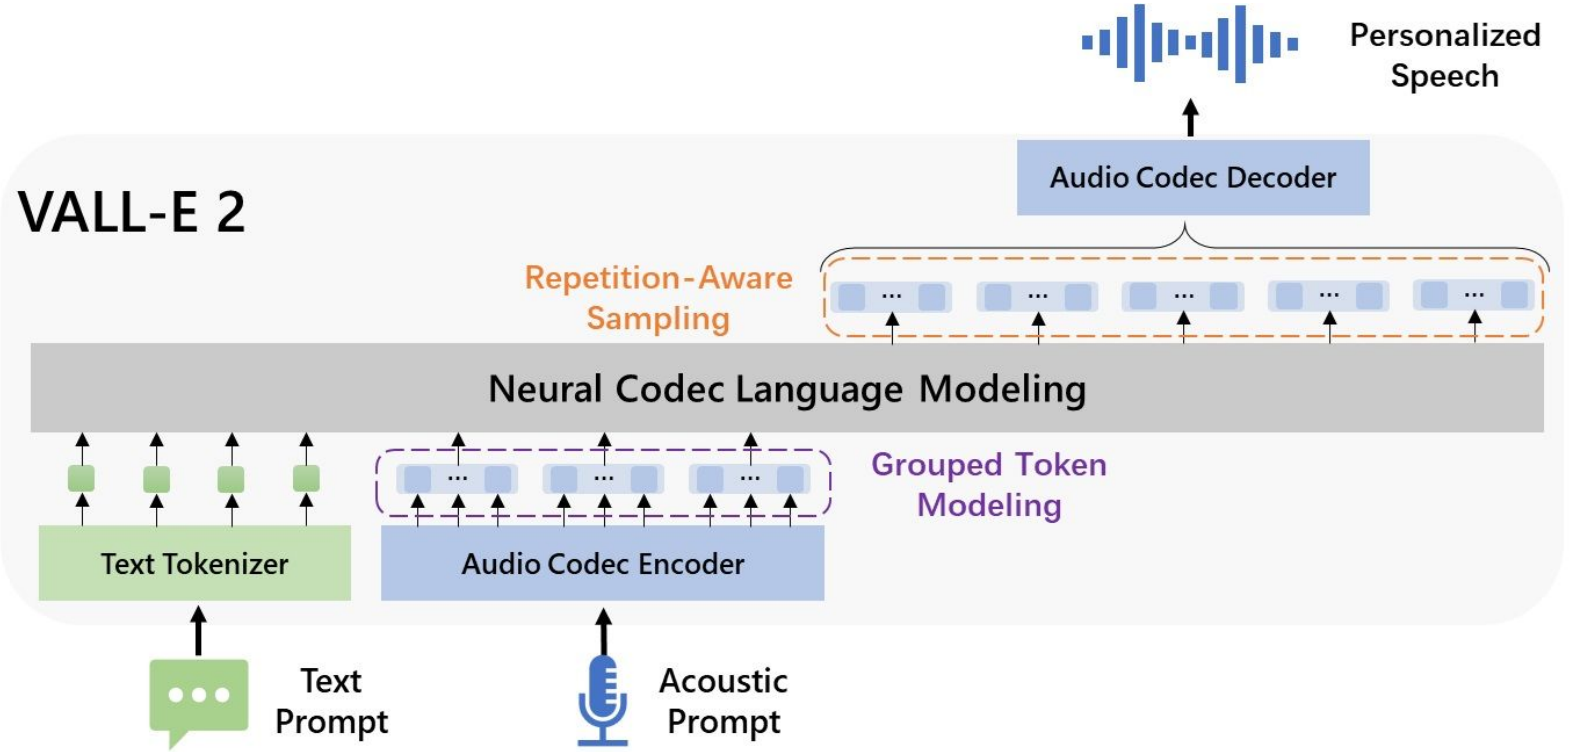
Personalized Speech
Audio Codec Decoder
VALL-E 2
Repetition-Aware Sampling
Neural Codec Language Modeling
Grouped Token Modeling
Text Tokenizer
Audio Codec Encoder
Text Prompt
Acoustic Prompt

Перенос особенностей речи

раздел 3

Global Style Token

- Идея: хотим иметь некоторое конечное число “токенов” - векторов с разными особенностями речи.

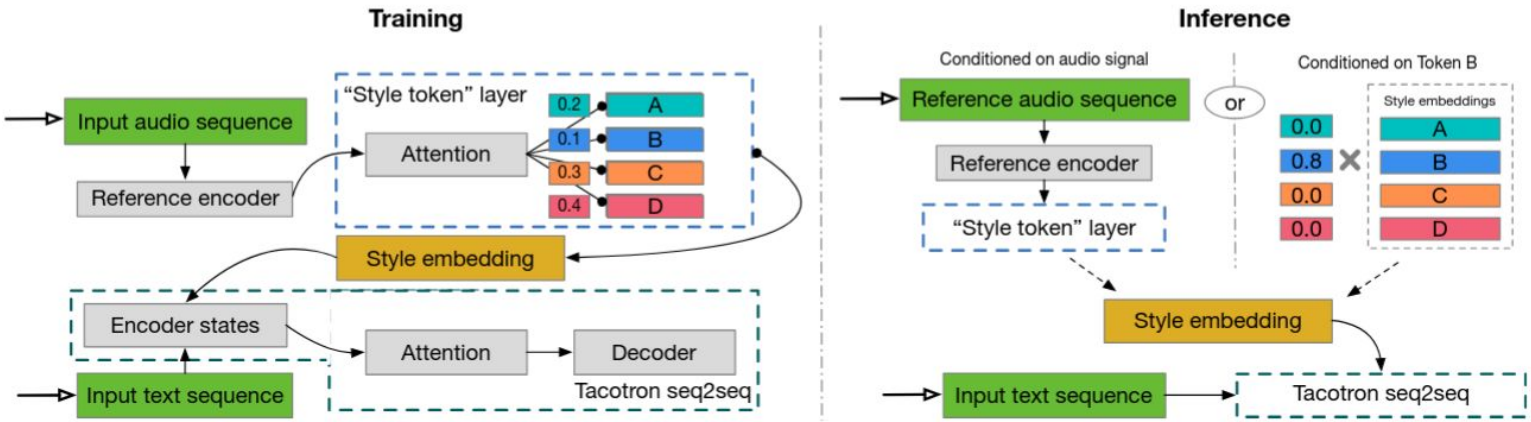

YourTTS

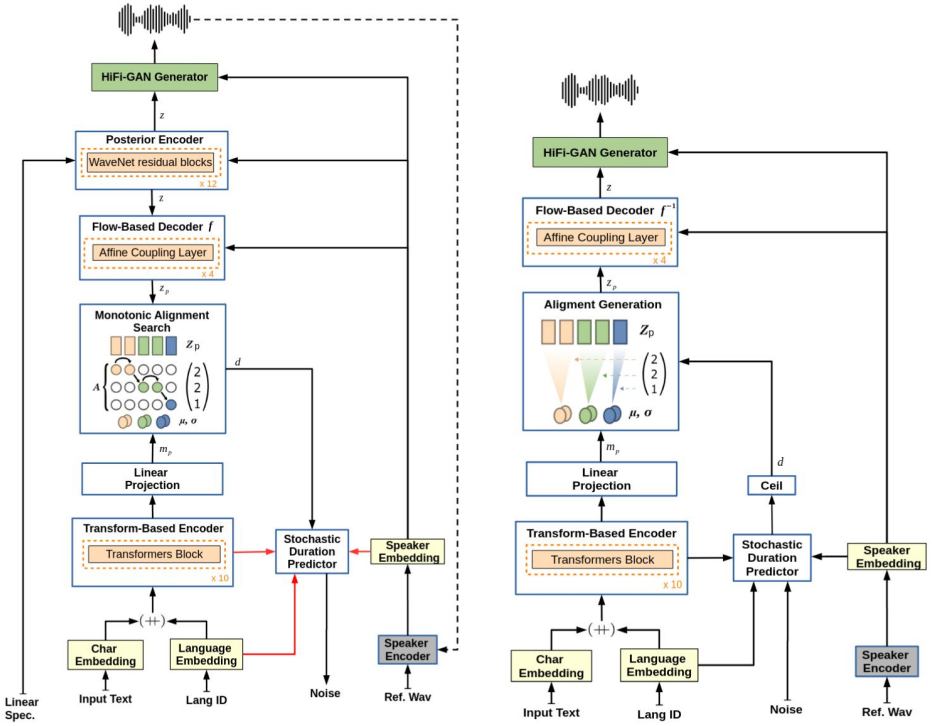

(a) Training procedure

(b) Inference procedure

Voice Cloning

- Будем менять голос на уже существующих аудио
- Существуют many-, few- и zero-shot подходы

Voice Cloning

- CycleGAN-VC

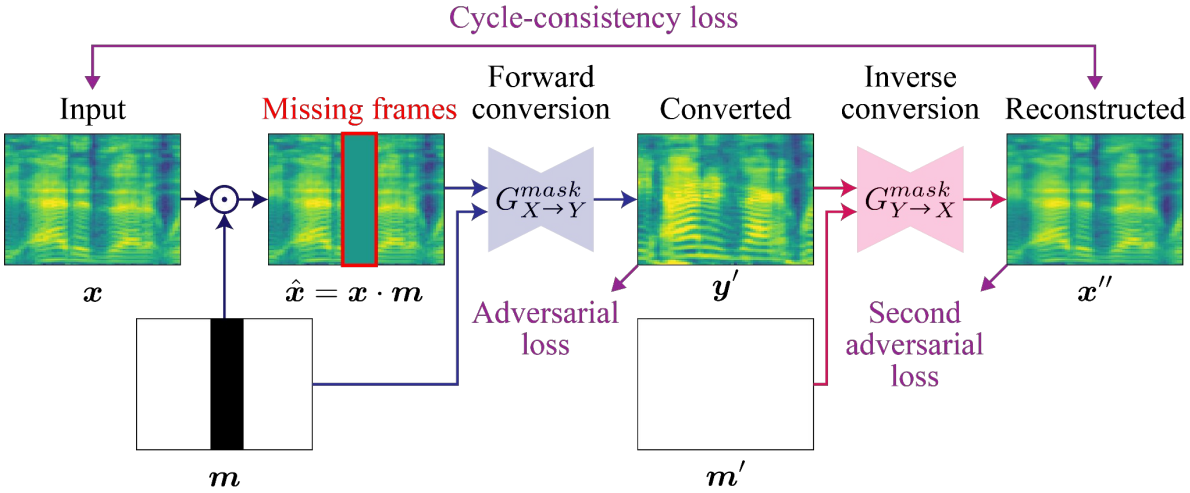

Voice Cloning

- AdaIN-VC
- AGAIN-VC

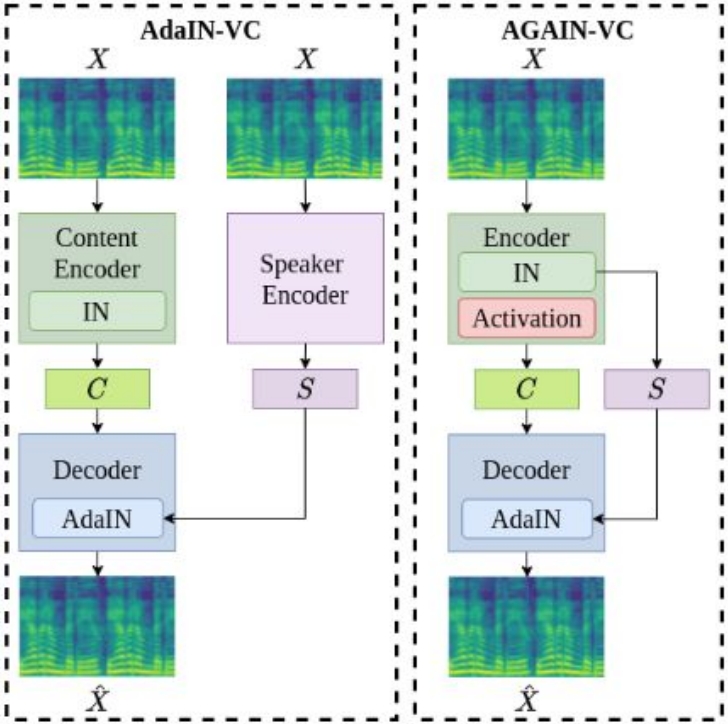

Выводы

раздел 1

Выводы

- Непрерывные модели не обладают погрешностью независимого подхода, но их сложнее обучать и контролировать
- Подход переноса особенностей речи позволяет быстрее и проще получать модели обученные под требуемый голос

Спасибо за внимание!